La estimación del operador de covarianza $\mathcal{C}$ en datos funcionales escasamente muestreados es el cuello de botella estadístico de toda inferencia FPCA y mFPCA en estudios endocrino-metabólicos: **toda la geometría del problema —eigenfunciones, scores BLUP, bandas de confianza— hereda el sesgo y la varianza de** $\hat{C}(s,t)$. En diseños periprandiales típicos ($n \approx 30$–50 sujetos, grilla común de 9 tiempos en $[0, 180]$ min con datos faltantes), el problema es híbrido entre el régimen *sparse genuino* de Yao, Müller & Wang (2005) y el régimen *balanced sparse* de Xiao et al. (2018), lo que condiciona la elección entre PACE, FACE/FACEs, RKHS y enfoques paramétricos no-estacionarios. Este documento ofrece un tratamiento riguroso de los fundamentos matemáticos, las propiedades asintóticas verificadas, las alternativas vigentes en la literatura (con atribuciones bibliográficas verificadas) y la implementación reproducible en `fdapace 0.6.0` y `MFPCA 1.3-11`, con énfasis en las consecuencias prácticas para la inferencia con hormonas entero-pancreáticas (GLP-1, GIP, grelina, PYY, insulina, glucosa). La conclusión metodológica central es que **para grillas balanceadas con missingness MCAR la estrategia óptima combina FACEs como estimador univariado de** $\hat{C}^{(ll)}$ **con la construcción multivariada de Happ–Greven**, garantizando positividad semidefinida (PSD) por construcción del operador conjunto.

---

1. El kernel de covarianza como objeto en $L^2(\mathcal{T} \times \mathcal{T})$ y su operador integral

Sea $X : \Omega \times \mathcal{T} \to \mathbb{R}$ un proceso estocástico cuadrado-integrable sobre $\mathcal{T} \subset \mathbb{R}$ compacto, con $E\{X(t)\} = \mu(t)$ y $E\int_{\mathcal{T}} X(t)^2\, dt < \infty$. El **kernel de covarianza** se define como

$$C(s,t) = \mathrm{Cov}\{X(s), X(t)\}, \qquad (s,t) \in \mathcal{T} \times \mathcal{T}.$$

Bajo continuidad de las trayectorias en $L^2(\Omega)$, $C \in L^2(\mathcal{T} \times \mathcal{T})$ y satisface tres propiedades estructurales que cualquier estimador $\hat{C}$ debe respetar para ser admisible:

1. **Simetría**: $C(s,t) = C(t,s)$.
2. **Positividad semidefinida** (PSD): $\sum_{i,j} \alpha_i \alpha_j\, C(t_i, t_j) \geq 0$ para todo conjunto finito $\{t_i, \alpha_i\}$.
3. **Continuidad**: $C \in \mathcal{C}(\mathcal{T} \times \mathcal{T})$ si X es continuo en media cuadrática, y C es Hilbert–Schmidt (HS) por integrabilidad.

El **operador integral covarianza** $\mathcal{C} : L^2(\mathcal{T}) \to L^2(\mathcal{T})$ está definido por

$$(\mathcal{C}f)(s) = \int_{\mathcal{T}} C(s,t)\, f(t)\, dt.$$

La propiedad PSD del kernel implica que $\mathcal{C}$ es **autoadjunto, compacto y positivo**, y por tanto admite una descomposición espectral discreta. El **teorema de Mercer** garantiza que, si C es continua y PSD,

$$C(s,t) = \sum_{k=1}^{\infty} \lambda_k \, \phi_k(s) \, \phi_k(t),$$

con convergencia uniforme y absoluta en $\mathcal{T} \times \mathcal{T}$, eigenvalores $\lambda_1 \geq \lambda_2 \geq \cdots \geq 0$, $\sum_k \lambda_k = \int_{\mathcal{T}} C(t,t)\, dt < \infty$ (operador *trace-class*) y eigenfunciones $\{\phi_k\}_{k\geq 1}$ ortonormales en $L^2(\mathcal{T})$. La descomposición de **Karhunen–Loève** (KL)

$$X(t) = \mu(t) + \sum_{k=1}^{\infty} \xi_k \, \phi_k(t), \quad \xi_k = \int_{\mathcal{T}} \{X(t) - \mu(t)\} \phi_k(t)\, dt, \quad E\xi_j \xi_k = \lambda_k \delta_{jk}$$

provee la base canónica para FPCA, donde la convergencia es en $L^2(\Omega)$ uniforme en t. **Bajo Gaussianidad, los scores $\xi_k \sim \mathcal{N}(0, \lambda_k)$ son independientes**, supuesto operativo del PACE para derivar el predictor BLUP de scores.

1.1 La asimetría sparse–denso y el problema de la "doble suma"

En el caso *denso* —cuando cada trayectoria X_i se observa en una grilla fina y común—, el estimador natural es la covarianza muestral puntual $\hat{C}(s,t) = (n-1)^{-1} \sum_{i=1}^{n} \{X_i(s) - \hat{\mu}(s)\}\{X_i(t) - \hat{\mu}(t)\}$, con tasa paramétrica $n^{-1/2}$. En el caso *sparse* la dificultad estructural es distinta: para un par genérico $(s,t) \in \mathcal{T} \times \mathcal{T}$ **no existe ningún sujeto i con observación simultánea en ambos puntos**, salvo en los nodos del grid común. La solución de Yao, Müller & Wang (2005, JASA) es realizar un **pooling de productos cruzados** sobre todos los sujetos y todas las parejas (j,l) con $j \neq l$,

$$\bigcup_{i=1}^{n} \big\{ (T_{ij}, T_{il},\, G_{i,jl}) : \, j \neq l \big\}, \qquad G_{i,jl} = \big(Y_{ij} - \hat{\mu}(T_{ij})\big)\big(Y_{il} - \hat{\mu}(T_{il})\big),$$

tratando cada producto como observación ruidosa de $C(T_{ij}, T_{il})$ y suavizando con un *smoother* bivariado. Esta nube de puntos vive en un dominio bidimensional, lo que activa la **maldición de la dimensionalidad**: la tasa óptima en MISE es $n^{-2r/(2r+d)} = n^{-2/3}$ para $d = 2$, $r = 2$ (Sobolev de orden 2), considerablemente más lenta que el $n^{-1/2}$ paramétrico. Esta diferencia tasa-régimen es la justificación matemática de que la estimación de C desde datos sparse no es un caso particular de la covarianza muestral, sino un **problema de regresión no paramétrica bidimensional con estructura simétrica y restricción PSD**.

---

2. El estimador PACE: derivación, exclusión de la diagonal y propiedades asintóticas

2.1 Modelo y suavizamiento univariado de la media

Yao, Müller & Wang (2005, *JASA* 100(470):577–590; DOI 10.1198/016214504000001745) postulan el modelo aditivo

$$Y_{ij} = X_i(T_{ij}) + \varepsilon_{ij} = \mu(T_{ij}) + \sum_{k=1}^{\infty} \xi_{ik}\phi_k(T_{ij}) + \varepsilon_{ij},$$

con $\varepsilon_{ij} \overset{iid}{\sim} (0, \sigma^2)$ independiente de $\{\xi_{ik}\}$, N_i aleatorio con $EN < \infty$ y $P(N > 1) > 0$. La media se estima por **regresión lineal local** (kernel 1D) minimizando $\sum_{i,j} K_1\big((T_{ij} - t)/h_\mu\big)\,\{Y_{ij} - \beta_0 - \beta_1(T_{ij} - t)\}^2$, con $\hat{\mu}(t) = \hat{\beta}_0$.

2.2 Suavizamiento bivariado de la covarianza: por qué se excluye la diagonal

La esperanza condicional clave del producto cruzado crudo es

$$E[G_{i,jl} \mid T_{ij}, T_{il}] \;\approx\; C(T_{ij}, T_{il}) + \sigma^2\,\delta_{jl}.$$

La diagonal $j = l$ contiene contaminación aditiva por la varianza del error, mientras los términos off-diagonal sólo contienen $C(s,t)$. Por ello PACE excluye explícitamente los pares $j = l$ del *smoothing* bivariado, ajustando

$$\hat{C}(s,t) = \arg\min_{\beta_0} \sum_{i=1}^{n} \sum_{j \neq l} K_2\!\left(\frac{T_{ij} - s}{h_C}, \frac{T_{il} - t}{h_C}\right)\!\big\{G_{i,jl} - \beta_0 - \beta_{11}(s - T_{ij}) - \beta_{12}(t - T_{il})\big\}^2,$$

con K_2 típicamente kernel producto Epanechnikov $K_2(u,v) = \frac{9}{16}(1-u^2)(1-v^2)\mathbf{1}_{[-1,1]^2}$. La separabilidad del kernel facilita el cómputo, no impone separabilidad estructural sobre C.

2.3 Estimación de σ^2 por extrapolación desde la diagonal

PACE construye dos estimadores complementarios de la varianza diagonal:

$$\tilde{V}(t) = \text{LL-1D}\big\{(Y_{ij} - \hat{\mu}(T_{ij}))^2\big\} \;\text{ estima }\; C(t,t) + \sigma^2;$$

$$\tilde{C}(t,t) = \text{LL-2D off-diag, rotado a la diagonal} \;\text{ estima }\; C(t,t).$$

Recortando las regiones de borde con $\mathcal{T}_1 = [\inf \mathcal{T} + |\mathcal{T}|/4,\, \sup \mathcal{T} - |\mathcal{T}|/4]$,

$$\boxed{\hat{\sigma}^2 = \frac{2}{|\mathcal{T}|} \int_{\mathcal{T}_1} \big\{\tilde{V}(t) - \tilde{C}(t,t)\big\}\,dt} \quad (\text{truncado a } 0 \text{ si negativo}).$$

El factor $2/|\mathcal{T}|$ es la fórmula publicada (no $1/|\mathcal{T}|$, una imprecisión que circula en la literatura secundaria); el integrando se evalúa sobre el intervalo central $\mathcal{T}_1$ que mide $|\mathcal{T}|/2$, lo que regenera el promedio.

2.4 Eigendescomposición empírica y predictor BLUP de scores

Resolviendo numéricamente la ecuación integral $\int_{\mathcal{T}} \hat{C}(s,t)\hat{\phi}_k(s)\,ds = \hat{\lambda}_k\hat{\phi}_k(t)$ sobre una grilla discreta (Rice & Silverman 1991; Capra & Müller 1997), bajo Gaussianidad el mejor predictor de los scores se obtiene como esperanza condicional (Mardia, Kent & Bibby 1979, Thm 3.2.4):

$$\hat{\xi}_{ik} = \hat{\lambda}_k\,\hat{\boldsymbol{\phi}}_{ik}^{\top}\,\hat{\Sigma}_{Y_i}^{-1}\,(\vec{Y}_i - \hat{\boldsymbol{\mu}}_i), \qquad (\hat{\Sigma}_{Y_i})_{j,l} = \hat{C}(T_{ij},T_{il}) + \hat{\sigma}^2\delta_{jl}.$$

Esta es la fórmula **BLUP** de PACE, fundamental cuando N_i es pequeño porque la integración numérica tipo $\int(X_i - \hat{\mu})\hat{\phi}_k$ sería inviable. Bajo no-Gaussianidad sigue siendo el mejor predictor lineal (BLP).

2.5 Selección de bandwidth y de K

Yao et al. (2005) proponen *one-curve-leave-out cross-validation* (Rice & Silverman 1991) y *generalized cross-validation* (GCV) para los anchos h_μ, h_C, h_V. La elección de K admite tres rutas: (i) CV sobre la trayectoria predicha; (ii) AIC pseudo-Gaussiano, $\mathrm{AIC}(K) = -2\hat{L}(K) + 2K$ con verosimilitud condicional sobre los scores estimados; (iii) **fracción de varianza explicada** $\sum_{k\le K}\hat{\lambda}_k / \sum_k \hat{\lambda}_k \ge p$, con $p \in \{0.85, 0.90, 0.95, 0.99\}$ por convención. Li, Wang & Carroll (2013, *JASA* 108(504):1284–1294) introducen un test secuencial para $\lambda_K = 0$.

2.6 Tasas asintóticas: PACE original, Hall–Müller–Wang y Li–Hsing

Las tasas de YMW (2005) son explícitamente subóptimas; **Hall, Müller & Wang (2006, *Ann. Stat.* 34(3):1493–1517) cierran el gap** demostrando que, bajo suavidad Sobolev de orden 2,

$$\|\hat{\phi}_k - \phi_k\| = O_p(n^{-2/5}), \qquad |\hat{\lambda}_k - \lambda_k| = O_p(n^{-1/2}),$$

con bandwidth óptimo $h_C \asymp n^{-1/5}$ —menor que el $h_C \asymp n^{-1/6}$ que sería óptimo para $\hat{C}$ puntual—. La razón es **semiparamétrica**: la integración contra funciones suaves ϕ_j en la eigenecuación realiza un *extra-smoothing* que mejora la tasa, requiriendo undersmoothing del nuisance bidimensional. **Li & Hsing (2010, *Ann. Stat.* 38(6):3321–3351)** generalizan a tasas uniformes casi-seguras y caracterizan la **transición de fase sparse↔denso** mediante los armónicos $\gamma_{nk} = (n^{-1}\sum_i m_i^{-k})^{-1}$. El cuadro siguiente sintetiza los resultados:

Cantidad	Régimen sparse ($m_i \le M$)	Régimen denso ($m_i \ge M_n \to \infty$)
$\sup_t,	\hat\mu(t)-\mu(t)	$
$\sup_{s,t},	\hat C(s,t)-C(s,t)	$

Cantidad	Régimen sparse ($m_i \le M$)	Régimen denso ($m_i \ge M_n \to \infty$)
$	\hat\sigma^2-\sigma^2	$
$\hat\lambda_k$	$O_p(n^{-1/2})$ (semiparamétrica)	$O_p(n^{-1/2})$
$\hat\phi_k$ (L^2 y uniforme)	$O_p(n^{-2/5})$ con $h \asymp n^{-1/5}$	$O_p(n^{-1/2})$

El umbral de transición es $m \asymp (n/\log n)^{1/4}$. **Para hormonas con $n=50$ y $m=9$ se está cerca pero del lado sparse**: no se gana la tasa paramétrica.

2.7 Garantía de positividad semidefinida

El estimador $\hat C$ obtenido por *smoothing* bivariado **no es PSD en general** (Hall, Müller & Yao 2008, *J. Multivariate Anal.* 99:1015–1034). La proyección de Frobenius-óptima al cono PSD es el **truncamiento de eigenvalores negativos** (Higham 1988, *Linear Algebra Appl.* 103:103–118):

$$\hat C_+ = \sum_{k:\hat\lambda_k \ge 0} \hat\lambda_k \, \hat\phi_k \hat\phi_k^\top = \arg\min_{C_+ \succeq 0} \|\hat C - C_+\|_F.$$

Este es el paso interno de `fdapace::FPCA()` que produce `fittedCov` (versión PSD usable para BLUP) a partir de `smoothedCov` (output crudo del *smoother* 2D). El cómputo subsidiario debe hacerse sobre `fittedCov`; reportar el rango de eigenvalores de `smoothedCov` como diagnóstico de violación PSD.

---

3. Suavizamiento local bivariado y maldición de la dimensionalidad

El estimador local lineal 2D minimiza

$$\sum_{i,j\neq l} K_2\!\left(\frac{T_{ij}-s}{h_s}, \frac{T_{il}-t}{h_t}\right)\!\left\{G_{i,jl} - \beta_0 - \beta_1(s-T_{ij}) - \beta_2(t-T_{il})\right\}^2.$$

La elección habitual es $h_s = h_t = h_C$ (isotropía) con kernel **producto Epanechnikov**, óptimo MSE de orden 2 entre kernels separables. Para covarianzas con estructura radial pronunciada (e.g., procesos estacionarios isotrópicos) un kernel radial puede reducir sesgo, pero rara vez es decisivo en la escala de $n \le 100$. La selección óptima de h_C por GCV o LOSO-CV admite tres heurísticas: AMISE-óptimo $h_C \asymp n^{-1/6}$, *plug-in* (constante derivada de las segundas derivadas de C, frecuentemente inestable) y `'GMeanAndGCV'` de `fdapace` —media geométrica entre el GCV óptimo y un piso mínimo viable, **estrategia recomendada en datos hormonales** por su robustez ante grillas casi-balanceadas.

La alternativa por **tensor product P-splines** (Eilers & Marx 1996; Wood 2003) o el *sandwich smoother* de Xiao, Li & Ruppert (2013, *JRSS-B* 75(3):577–599),

$$\hat{Y} = S_1 Y S_2', \qquad S_k = B_k(B_k^\top B_k + \lambda_k D_k^\top D_k)^{-1} B_k^\top,$$

reduce la complejidad de $O(n^3)$ del *thin-plate* a $O(n_1 n_2(c_1 + c_2))$, hace tractable la imposición de simetría $\Theta = \Theta^\top$ y permite penalización de doble diferencia. Esta estructura es la base del FACE/FACEs y conviene preferirla al *thin-plate spline* genérico de `mgcv::s(s,t,bs='tp')` —que **no fuerza simetría ni PSD** y no fue diseñado para covarianzas—.

---

4. Estimación conjunta de μ y C: propagación de error y métodos integrados

PACE estima $\hat{\mu}$ y $\hat{C}$ **secuencialmente**: $\hat{C}$ se construye sobre los residuales $Y_{ij} - \hat{\mu}(T_{ij})$. El sesgo de $\hat{\mu}$ se propaga aditivamente a $\hat{C}$:

$$\hat{C}(s,t) = C(s,t) + \big[\mu(s) - \hat{\mu}(s)\big]\big[\mu(t) - \hat{\mu}(t)\big] + O_p\big((nh_C^2)^{-1/2}\big),$$

término sesgo que es de orden $O_p((nh_\mu)^{-1})$. Para grillas balanceadas con missingness MCAR la *cross-sectional mean* puntual $\hat{\mu}_{\mathrm{cs}}(t_j) = \bar{Y}_{\cdot j}$ es insesgada y eficiente; PACE smoothing añade sesgo sólo si h_μ es excesivo respecto al ancho de los picos postprandiales. **En hormonas, donde la media tiene estructura claramente unimodal con pico agudo ($\sim$30 min para insulina/GLP-1, $\sim$60 min para glucosa, nadir $\sim$60–90 min para grelina), la sub-suavización es preferible** para no aplanar la dinámica. La estimación **conjunta** $(\hat{\mu}, \hat{C})$ por verosimilitud penalizada (Cai & Yuan 2010; FACEs de Xiao et al. 2018) propaga el error de manera más coherente y es la estrategia metodológicamente preferida.

---

5. La varianza del ruido σ^2 y su separación de la varianza funcional

La descomposición fundamental de la diagonal,

$$\mathrm{Var}\{Y_{ij} \mid T_{ij} = t\} = C(t,t) + \sigma^2,$$

es lo que permite identificar σ^2 por la diferencia entre la varianza marginal observada y la integral de la diagonal extrapolada de $\hat{C}$ off-diagonal (sección 2.3). Métodos alternativos:

1. **Diferencias contiguas** (Hall, Kay & Titterington 1990): para grillas balanceadas, $\hat{\sigma}^2 = \frac{1}{2(m-1)} \sum_{j=1}^{m-1} (Y_{i,j+1} - Y_{i,j})^2$ promediado sobre sujetos. Funciona bien si la grilla es densa respecto a la escala de variación de X —marginal en grillas hormonales donde el pico postprandial cambia 30–50% entre $t=0$ y $t=30$, contaminando la diferencia con varianza funcional genuina.
2. **Penalized splines con efecto aleatorio Gaussiano** (Goldsmith et al., `refund::fpca.sc`): σ^2 se estima por REML como componente de varianza residual del modelo mixto.
3. **FACEs**: estimación conjunta de Θ (coeficientes tensor-producto) y σ_ε^2 aprovechando explícitamente la diagonal,

$$(\hat{\Theta}, \hat{\sigma}_\varepsilon^2) = \arg\min \Big\{ \sum_i (\hat{C}_i - X_i \alpha)^\top W_i (\hat{C}_i - X_i \alpha) + \lambda \|\Theta D\|_F^2 \Big\},$$

   con simetría $\Theta = \Theta^\top$ impuesta por construcción. **Esta es la única ruta que respeta la unidad muestral "sujeto"** (no la observación), corrigiendo un sesgo conocido de `fpca.sc`.

Para hormonas, σ^2 tiene **interpretación dual**: variabilidad analítica del ensayo (CV intra-ensayo de 5–20% para ELISA/RIA) y variabilidad biológica intra-individual no capturada por el modelo. Si el CV analítico es conocido a priori (e.g., del kit), conviene **fijar** `**userSigma2**` en `fdapace::FPCA()` en lugar de estimarlo, particularmente cuando $n < 30$ y la diagonal está mal estimada.

---

6. Alternativas al PACE: panorama metodológico

6.1 FACE y FACEs: tensor-product P-splines simétricos

El método **FACE** (Xiao, Ruppert, Zipunnikov & Crainiceanu 2016, *Stat. Comput.* 26(1–2):409–421) usa el *sandwich smoother* con penalización de doble diferencia para covarianza en datos densos. Su extensión a sparse, **FACEs** (Xiao, Li, Checkley & Crainiceanu 2018, *Stat. Comput.* 28(3):511–522), es metodológicamente la opción dominante para grillas balanceadas con missingness:

$$\hat{C}(s,t) = \sum_{\kappa,\ell} \theta_{\kappa\ell} \, B_\kappa(s) \, B_\ell(t), \qquad \theta_{\kappa\ell} = \theta_{\ell\kappa} \ \ (\text{simetría}),$$

con σ_ε^2 estimado conjuntamente, ponderaciones W_i que captan la correlación intra-sujeto de las variables auxiliares $\hat{C}_{i,j_1 j_2} = \hat{r}_{ij_1} \hat{r}_{ij_2}$ y selección de λ por **leave-one-subject-out CV**. Las simulaciones publicadas (Xiao et al. 2018) muestran que FACEs supera a `fpca.sc`, *thin-plate regression splines*, MLE Matérn y PACE/local-poly en MISE para $m \leq 10$, **siendo**

$\sim$15–35× más rápido. Implementación CRAN: `face::face.sparse()`. Existe **NO existe un paper "FACE" en JASA**: la atribución habitual es errónea; las publicaciones reales son JRSS-B 2013 (sandwich), Stat. Comput. 2016 (FACE denso) y Stat. Comput. 2018 (FACEs sparse).

6.2 Regularización RKHS y tasas minimax: Cai–Yuan

Cai & Yuan (2010, technical report Penn–Georgia Tech) y Cai & Yuan (2011, *Ann. Stat.* 39(5):2330–2355) formalizan la estimación de C en un RKHS $\mathcal{H}(K\otimes K)$ con penalización $\lambda\|C\|^2_{\mathcal{H}(K\otimes K)}$. El resultado clave es la **transición de fase**: para *common design* con sample paths Sobolev de orden r, la tasa óptima de la media es $(nm)^{-2r/(2r+1)}$ si $m\leq n^{1/(2r)}$ y n^{-1} si $m>n^{1/(2r)}$. Para covarianza, el marco tensor-producto RKHS evita la maldición bidimensional gracias al *smoothing* implícito de la estructura producto. **Limitación práctica**: el método tiene código de los autores pero **no existe un paquete CRAN canónico**, y con $n<50$ la elección de λ por CV es inestable.

6.3 Modelos paramétricos del kernel

La familia **Matérn**

$$C(s,t)=\sigma^2\,\frac{2^{1-\nu}}{\Gamma(\nu)}\left(\frac{\sqrt{2\nu}\,|s-t|}{\rho}\right)^{\nu}K_\nu\left(\frac{\sqrt{2\nu}\,|s-t|}{\rho}\right)$$

y la **squared exponential** $C(s,t)=\sigma^2\exp\{-(s-t)^2/(2\ell^2)\}$ admiten estimación por verosimilitud marginal,

$$\log p(Y\mid\theta,\sigma_\varepsilon^2)=-\tfrac{1}{2}(Y-\mu)^\top(K_\theta+\sigma_\varepsilon^2 I)^{-1}(Y-\mu)-\tfrac{1}{2}\log|K_\theta+\sigma_\varepsilon^2 I|-\tfrac{N}{2}\log(2\pi).$$

El problema fundamental para hormonas periprandiales es la no-estacionariedad: la varianza $\sigma^2(t)$ cambia masivamente entre baseline y pico postprandial (factor 2–10× en insulina y GLP-1), violando el supuesto $C(s,t)=C(|s-t|)$. Matérn estacionaria isotrópica **subestimaría sistemáticamente la varianza en los picos y la sobreestimaría en las mesetas**, con consecuencias graves para la cobertura de bandas de confianza. La construcción no-estacionaria de **Paciorek & Schervish (2006, *Environmetrics* 17(5):483–506)** —kernels variables $\Sigma(s)$ con suavidad y PSD garantizada— es el modelo paramétrico conceptualmente apropiado, pero requiere implementación custom en Stan o `nimble` y converge lentamente con $n=30$–50.

6.4 Enfoques bayesianos no paramétricos

Suarez & Ghosal (2017, *Bayesian Anal.* 12(2):311–333) modelan C por descomposición espectral aproximada con prior inverso-Wishart sobre la matriz de coeficientes y demuestran consistencia posterior. Wilson & Ghahramani (2011) introducen los **Generalised Wishart Processes**: $\Sigma(t)=L(t)L(t)^\top$ con entradas Cholesky GP-distribuidas,

útil para covarianzas que evolucionan en el tiempo. El paquete `brms` permite priors GP en regresión, pero **no hay paquete CRAN canónico para Bayesian FPCA con priors no-paramétricos sobre eigenfunciones**, y el costo computacional MCMC con $n=50$ y diagnósticos de convergencia honestos es elevado. Adecuado como análisis de sensibilidad en material suplementario, no como método principal en JCEM.

6.5 Separabilidad

Aston, Pigoli & Tavakoli (2017, *Ann. Stat.* 45(4):1431–1461) y Descary & Panaretos (2019, *Ann. Stat.* 47(1):1–38) estudian descomposiciones $C((s,x),(t,y)) = C_T(s,t)\, C_X(x,y)$ que reducen los parámetros de $O(K^4)$ a $O(2K^2)$. **No aplica directamente al caso univariado en tiempo**, pero es relevante para análisis multivariados que combinan tiempo postprandial con condición experimental (e.g., comida estándar vs. variantes). En el contexto de mFPCA con 6 hormonas, podría explorarse en material suplementario.

6.6 Tabla comparativa de métodos

Método	Idea central	Penalización	$\hat{\sigma}^2$	Implementación R	Apto $n=$ $m=9$
PACE (Yao 2005)	LL bivariado off-diagonal	bandwidth h_C	extrapolación diagonal	`fdapace::FPCA`	Sí; banc crítico
FACEs (Xiao 2018)	P-spline tensor simétrico	$\lambda\lVert\Theta D\rVert_F^2$	conjunto con Θ	`face::face.sparse`	**Recom**
fpca.sc (Goldsmith 2011)	Tensor B-spline + GAM	REML/GCV	mediana diagonal	`refund::fpca.sc`	Sí; sesg muestra
fpca.face (Xiao 2016)	*Sandwich smoother*	doble diferencia	sí	`refund::fpca.face`	Sí si mis <30%
RKHS Cai–Yuan (2010)	Tensor RKHS	$\lambda\lVert C\rVert_{\mathcal{H}\otimes\mathcal{H}}^2$	externo	código autores	Asintóti óptima; a n peq
Matérn estacionaria	Cov isotrópica	–	marginal MLE	`mgcv` (`bs='gp'`)	**No** (no-estacio hormon
Matérn no-estac. (Paciorek 2006)	Kernel $\Sigma(t)$ variable	–	marginal MLE	custom Stan/nimble	Concep ideal; c

Método	Idea central	Penalización	$\hat{\sigma}^2$	Implementación R	Apto $n=$ $m=9$
Bayesian FPCA (Suarez–Ghosal 2017)	Espectral + IW prior	RJ-MCMC	conjunto	código autores	Análisis sensibil

---

7. Estimación multivariada: el marco mFPCA de Happ–Greven

7.1 Operador conjunto y descomposición de Karhunen–Loève multivariada

Para un proceso multivariado $\mathbf{X} = (X^{(1)}, \ldots, X^{(p)})$ con $X^{(j)} \in L^2(\mathcal{T}_j)$ —en hormonas, $\mathcal{T}_j = [0, 180]$ min para todo j—, **Happ & Greven (2018, *JASA* 113(522):649–659; DOI 10.1080/01621459.2016.1273115)** trabajan en el espacio Hilbert producto $\mathbb{H} = \prod_{j=1}^{p} L^2(\mathcal{T}_j)$ con producto interno (potencialmente ponderado por $w_j > 0$)

$$\langle\langle f, g \rangle\rangle_w = \sum_{j=1}^{p} w_j \int_{\mathcal{T}_j} f^{(j)}(t) g^{(j)}(t)\, dt.$$

La matriz de operadores $\mathcal{C} = [\, C^{(jk)} \,]_{j,k=1}^{p}$ con $C^{(jk)}(s,t) = \mathrm{Cov}(X^{(j)}(s), X^{(k)}(t))$ define un operador autoadjunto, compacto y positivo en $\mathbb{H}$ bajo continuidad uniforme y $\|C^{(jk)}(\cdot, t)\|^2 < K_{jk}$. Mercer y KL multivariados implican

$$X^{(j)}(t) = \mu^{(j)}(t) + \sum_{m=1}^{\infty} \rho_m \psi_m^{(j)}(t), \quad \mathrm{Cov}(\rho_m, \rho_n) = \nu_m \delta_{mn}, \quad \nu_1 \geq \nu_2 \geq \cdots \geq 0.$$

7.2 Por qué la estimación directa de $C^{(jk)}$ con $j \neq k$ es más difícil

Para $C^{(jj)}(s,t)$ los productos cruzados $G_i^{jj}(s,t) = (Y_{ij}^{(j)} - \hat{\mu}^{(j)})(Y_{il}^{(j)} - \hat{\mu}^{(j)})$ provienen del mismo sujeto y la misma función, lo que permite *pooling* 2D directo. Para $C^{(jk)}(s,t)$ con $j \neq k$ los productos $G_i^{jk} = (Y_{ij}^{(j)} - \hat{\mu}^{(j)})(Y_{il}^{(k)} - \hat{\mu}^{(k)})$ requieren mediciones simultáneas de ambas hormonas. **En el diseño periprandial este es el caso favorable de "concurrent sampling"**: las 6 hormonas se determinan en la misma alícuota de plasma a cada $t \in \{0, 15, \ldots, 180\}$, lo que permite *pooling* 2D bivariado por par. Pero la elección de $p(p+1)/2 = 21$ bandwidths separados (con $p = 6$) multiplica la inestabilidad: **el riesgo de covarianzas cruzadas espurias por bandwidths heterogéneos es alto**.

7.3 Algoritmo Happ–Greven y garantía PSD por construcción

La solución elegante de Happ–Greven evita el *smoothing* 2D directo de las covarianzas cruzadas:

1. **uFPCA por componente**: para $j = 1, \ldots, p$ aplicar PACE/FACEs y obtener $(\hat{\mu}^{(j)}, \hat{C}^{(jj)}, \{\hat{\lambda}_k^{(j)}, \hat{\phi}_k^{(j)}\}_{k=1}^{M_j}, \hat{\xi}_{i,k}^{(j)})$. Selección de M_j por PVE univariada $\alpha \in [0.90, 0.99]$.
2. **Concatenación de scores**: $\Xi \in \mathbb{R}^{n \times M_+}$ con $M_+ = \sum_j M_j$, donde $\Xi_{i,\cdot} = (\hat{\xi}_{i,1}^{(1)}, \ldots, \hat{\xi}_{i,M_p}^{(p)})$.
3. **Eigendescomposición matricial**: $\hat{Z} = (n-1)^{-1}\Xi^\top \Xi$, eigenvectores $\hat{\mathbf{c}}_m$ con eigenvalores $\hat{\nu}_m$.
4. **Eigenfunciones multivariadas**: $\hat{\psi}_m^{(j)}(t) = \sum_{k=1}^{M_j} [\hat{\mathbf{c}}_m]_k^{(j)} \hat{\phi}_k^{(j)}(t)$.
5. **Scores multivariados**: $\hat{\rho}_{i,m} = \Xi_{i,\cdot}\hat{\mathbf{c}}_m$.

La garantía PSD del operador conjunto es automática: $\hat{Z}$ es matriz de Gram, por construcción simétrica PSD, sus eigenvalores son no-negativos y la reconstrucción $\sum_m \hat{\nu}_m \hat{\psi}_m \otimes \hat{\psi}_m$ hereda la propiedad. **Este es el argumento decisivo a favor de Happ–Greven sobre la estimación directa de $C^{(jk)}$ por pares**, que no garantiza PSD del operador $p \times p$.

7.4 Tasas asintóticas y propagación de error

Bajo (A1)–(A5) de Happ & Greven (Prop. 7), con r_n^Γ la tasa de convergencia uniforme de $\hat{C}^{(jj)}$ (PACE provee $n^{-1/2}h^{-2}$) y $\Delta_M = \max_j(\lambda_m - \lambda_{m+1})^{-1}$ el inverso del *eigenvalue gap*:

$$|\nu_m^{[M]} - \hat{\nu}_m| = O_p\big(M_{\max} \cdot \max\{n^{-1/2},\, \Delta_M r_n^\Gamma\}\big),$$

$$\|\psi_m^{[M]} - \hat{\psi}_m\| = O_p\big(M_{\max}^{3/2} \cdot \max\{n^{-1/2},\, \Delta_M r_n^\Gamma\}\big).$$

Para $n = 30$–50 esto subraya la importancia de no inflar M_j: la propagación de error es lineal en $M_{\max}$ para eigenvalores y cuadrática-y-media para eigenfunciones.

7.5 Una advertencia metodológica reciente: PVE univariada $\not\Rightarrow$ PVE multivariada

Golovkine, Gunning, Simpkin & Bargary (2025, *Commun. Stat. Simul. Comput.*; DOI 10.1080/03610918.2025.2459862; arXiv:2311.04540) demuestran que seleccionar M_j por PVE univariada al α% **no garantiza PVE multivariada al α%**. La estrategia recomendada para hormonas es: (i) fijar M_j generosos (e.g., $M_j = 5$, total $M_+ = 30$), (ii) calcular $\hat{Z}$ y diagonalizar, (iii) seleccionar M conjunto por PVE multivariada ≥ 0.85–0.90, (iv) verificar sensibilidad re-corriendo con $M_j \pm 1$ y comparando $\hat{\psi}_1, \hat{\psi}_2$ con bandas bootstrap.

7.6 Alternativas multivariadas

- **Chiou, Chen & Yang (2014, *Statistica Sinica* 24(4):1571–1596)**: mFPCA por normalización puntual $C^{(jj)}(t,t)^{1/2}$ y construcción de cross-correlations $R^{(jk)}(s,t)$.

Pierde flexibilidad en dominios mixtos.

- **Berrendero, Justel & Svarc (2011, *CSDA* 55(9):2619–2634)**: PCA puntual sobre $\Sigma(t)$, produce *eigenvalue functions*; conceptualmente distinto.
- **mFACEs / `mfaces`** (Li, Xiao & Luo 2020, *Stat* 9:e245): extensión multivariada de FACEs con tensor-producto B-spline penalizado y bootstrap; PSD por estructura. **Es la única alternativa CRAN-madura con propiedades comparables a Happ–Greven**, particularmente eficiente cuando todas las hormonas comparten grilla y se desea estimación conjunta directa de auto- y cross-covarianzas.

---

8. Implementación reproducible: `fdapace 0.6.0` y `MFPCA 1.3-11`

8.1 Estado verificado de los paquetes (mayo 2026, CRAN)

Paquete	Versión	Mantenedor	Última publicación CRAN
`fdapace`	**0.6.0**	Yidong Zhou (UC Davis, sucede a Hadjipantelis/Carroll)	2024-07-03 (vigente; sin 0.6.1/0.7)
`MFPCA`	**1.3-11**	Clara Happ-Kurz	2025-08-27
`funData`	$\geq 1.3\text{-}9$	Clara Happ-Kurz	dependencia obligatoria de MFPCA
`face`	$\geq 0.1\text{-}7$	Luo Xiao	implementación FACEs sparse
`refund`	$\geq 0.1\text{-}30$	Goldsmith/Scheipl/Greven	`fpca.sc`, `fpca.face`, `fbps`

8.2 Argumentos críticos de `fdapace::FPCA(Ly, Lt, optns)`

Opción	Default	Recomendación hormonas
`dataType`	autodetectado	**`'Sparse'`** explícito
`kernel`	`'gauss'` en sparse, `'epan'` en dense	**`'epan'`** o `'quar'` (preserva pico postprandial)
`methodMuCovEst`	`'smooth'`	mantener `'smooth'` (PACE)
`methodBwMu` / `methodBwCov`	`'GCV'`	**`'GMeanAndGCV'`** (más estable)
`methodSelectK`	`'FVE'`	`'FVE'` con `FVEthreshold=0.95`

Opción	Default	Recomendación hormonas
`FVEthreshold`	`0.99` (en $\ge$0.6)	**`0.95`** para interpretabilidad
`error`	`TRUE`	`TRUE` (asume σ^2 aditivo)
`methodXi`	`'CE'` (BLUP)	`'CE'`
`methodRho`	`'vanilla'`	**`'trunc'`** o `'ridge'` (estabiliza $\Sigma_{Y_i}^{-1}$)
`useBinnedData`	`'AUTO'`	**`'OFF'`** para sparse genuino
`nRegGrid`	`51`	`101` para superficies suaves
`rotationCut`	`c(0.25,0.75)`	mantener (excluye bordes en $\hat{\sigma}^2$)
`userSigma2`	`NULL`	fijar al CV² del ensayo si conocido

El objeto retornado contiene `$smoothedCov` (output crudo del *smoother* 2D; puede tener eigenvalores negativos pequeños) y `$fittedCov` ($= \sum_{k \le K} \hat{\lambda}_k \hat{\phi}_k \hat{\phi}_k^\top$, **PSD por construcción** vía `GetEigenAnalysisResults`, siguiendo Hall, Müller & Yao 2008). **Toda inferencia debe usar `fittedCov`**; reportar el rango de eigenvalores de `smoothedCov` como diagnóstico.

8.3 Argumentos de `MFPCA::MFPCA(mFData, M, uniExpansions, ...)`

Argumento	Recomendación hormonas
`M`	≤ 6 con $n = 30$–50
`uniExpansions`	lista de longitud p; tipo `'uFPCA'` con `pve=0.95`, `npc` generoso, `makePD=TRUE`
`weights`	$w_j = 1/\mathrm{tr}(\hat{C}^{(jj)})$ para escalas heterogéneas
`fit`	`TRUE` (reconstrucción KL truncada)
`bootstrap`	`TRUE`, `nBootstrap≥500`, `bootstrapAlpha=c(0.05,0.10)`
`bootstrapStrat`	factor clínico (e.g., normoglucémico vs T2D)
`approx.eigen`	`FALSE` con $M_+ \le 50$; `TRUE` para problemas mayores (usa `irlba`)

Aclaración crítica que debe figurar en Métodos: aunque el tipo se llame `'uFPCA'`, la implementación interna `MFPCA::PACE` **no invoca `fdapace::FPCA`** sino un GAM bivariado con tensor B-splines vía `mgcv::gam` (estilo `refund::fpca.sc`, basado en Di et al. 2009). Para usar PACE de Yao–Müller–Wang propiamente, se debe descomponer cada hormona con `fdapace::FPCA()` y pasar las bases a `MFPCA` con `type='given'`. Citar entonces

explícitamente Yao, Müller & Wang (2005) o Di, Crainiceanu, Caffo & Punjabi (2009, *Ann. Appl. Stat.* 3(1):458–488) según corresponda.

8.4 Pseudocódigo R reproducible

```
suppressPackageStartupMessages({
  library(fdapace); library(MFPCA); library(funData)
  library(face); library(dplyr); library(tidyr)
})

## 1. Pre-procesamiento: log-transform y formato long ---------------
df_log <- df %>%
  mutate(value = log(pmax(value, lod/sqrt(2))))   # imputación LOD/sqrt(2)

to_LyLt <- function(d) {
  d <- d[order(d$subject_id, d$time_min), ]
  list(Lt = split(d$time_min, d$subject_id),
       Ly = split(d$value,    d$subject_id))
}
hormones <- levels(df_log$hormone)
data_h   <- lapply(hormones, function(h) to_LyLt(subset(df_log, hormone ==
h)))
names(data_h) <- hormones

## 2. Diagnóstico de cobertura del producto cartesiano de tiempos ---
op <- par(mfrow = c(2, 3))
for (h in hormones)
  CreateDesignPlot(Lt = data_h[[h]]$Lt, isColorPlot = TRUE, yname = h)
par(op)

## 3. FPCA univariada por hormona (PACE) ----------------------------
optns <- list(dataType = "Sparse", kernel = "epan",
              methodMuCovEst = "smooth",
              methodBwMu = "GMeanAndGCV", methodBwCov = "GMeanAndGCV",
              methodSelectK = "FVE", FVEthreshold = 0.95,
              error = TRUE, methodXi = "CE", methodRho = "trunc",
              useBinnedData = "OFF", nRegGrid = 101, verbose = TRUE)
fpca_list <- lapply(data_h, function(d) FPCA(d$Ly, d$Lt, optns = optns))

## 3b. ALTERNATIVA / sensibilidad: FACEs (recomendado para grilla
balanceada)
##     Requiere df en formato (subj, argvals, y) por hormona.
faces_list <- lapply(hormones, function(h) {
  long <- subset(df_log, hormone == h)
  face.sparse(data = data.frame(subj = long$subject_id,
                                argvals = long$time_min,
```

```r
                                y = long$value),
              argvals.new = seq(0, 180, by = 2),
              knots = 7, p = 3, m = 2, lambda = NULL, search.length = 14)
})

## 4. Diagnósticos de PSD y bandwidth -------------------------------
diag_tbl <- do.call(rbind, lapply(hormones, function(h) {
  o <- fpca_list[[h]]
  data.frame(hormone = h, K = o$selectK, FVE = round(o$FVE, 3),
             sigma2  = signif(o$sigma2, 3),
             bwMu    = signif(o$bwMu,   3),
             bwCov   = signif(o$bwCov,  3),
             min_eig_smoothed = signif(min(eigen(o$smoothedCov,
                                  only.values = TRUE)$values), 3))
}))
print(diag_tbl)

## 5. Ensamblaje multiFunData y MFPCA conjunto (Happ-Greven) -------
build_funData <- function(o) {
  K <- o$selectK
  X <- sweep(o$xiEst[, 1:K, drop = FALSE] %*% t(o$phi[, 1:K, drop = FALSE]),
             2, -o$mu)
  funData(argvals = o$workGrid, X = X)
}
mFD <- multiFunData(lapply(fpca_list, build_funData))
w   <- 1 / sapply(fpca_list, function(o) sum(o$lambda))   # pesos por traza

mfpca_fit <- MFPCA(mFD, M = 6,
                   uniExpansions = lapply(fpca_list, function(o)
                     list(type = "given",
                          functions = funData(o$workGrid, t(o$phi)),
                          scores    = o$xiEst, ortho = TRUE)),
                   weights = w, fit = TRUE,
                   bootstrap = TRUE, nBootstrap = 1000,
                   bootstrapAlpha = c(0.05, 0.10), verbose = TRUE)

summary(mfpca_fit); plot(mfpca_fit); scoreplot(mfpca_fit)
```

8.5 Diagnósticos numéricos y problemas comunes

La tabla siguiente resume los síntomas, causas y remedios en el ajuste práctico:

Síntoma	Causa probable	Remedio
Eigenvalores inflados, primer K explica $> \$99$ muy rugosa	h_C demasiado pequeño	subir `userBwCov` o `'GMeanAndGCV'`

Síntoma	Causa probable	Remedio
Pico postprandial aplanado, $\hat{\phi}_1$ excesivamente suave	h_C demasiado grande	bajar bandwidth; usar kernel de soporte compacto
`sigma2` negativo o ≈ 0	`rotationCut` atrapa pico	ajustar a `c(0.15,0.85)` o fijar `userSigma2`
`xiVar` con valores enormes	Σ_{Y_i} mal condicionada	`methodRho='ridge'`
Aviso "covariance not non-negative definite"	normal: usar `fittedCov` para inferencia	–
Covarianzas cruzadas espurias en mFPCA	$\hat{\mu}^{(j)}$ sobre-suavizada	reducir $h_\mu^{(j)}$; reportar bandas bootstrap

Visualización mínima a reportar: `persp` o `filled.contour` de `fittedCov`, `CreateDesignPlot` de cobertura, `CreateScreePlot` con FVE acumulado, eigenfunciones $\hat{\phi}_k$ con bandas bootstrap, y heatmap de la matriz residual $\hat{C} - S^{\text{emp}}$ en la grilla común.

---

9. Aspectos específicos del análisis de hormonas entero-pancreáticas periprandiales

9.1 Variabilidad de fase: el vaciado gástrico como confundente estructural

El tiempo medio de vaciado gástrico ($T_{1/2} \approx 50$–90 min en sanos, 110–130 min en T1D y gastroparesia) modula el tiempo del pico hormonal: GLP-1 alcanza su máximo a 15–30 min, GIP a 30–45, insulina a $\sim \$30, glucs\$30$–$60$, y el nadir de grelina cae en 60–90. **La variabilidad inter-individual del tiempo de pico es la fuente principal de variabilidad de fase**, y produce un artefacto bien caracterizado: si no se separa, la fase no removida **infla la diagonal y los off-diagonales de $\hat{C}$, y la primera eigenfunction tiende a parecerse a la derivada de la curva media** —patrón típico de fase, no de amplitud— como demuestran teóricamente Marron, Ramsay, Sangalli & Srivastava (2015, *Statist. Sci.* 30(4):468–484; arXiv:1512.03216).

La recomendación operativa es **inspeccionar la dispersión de t_{peak} inter-sujeto y, si excede $\sim$15–20 min para glucosa o insulina, aplicar registration**. Las opciones son: (i) **landmark registration** (Ramsay & Silverman 2005, cap. 7) cuando el pico está bien definido; (ii) **alineación de Fisher–Rao / SRSF** (Tucker, Wu & Srivastava 2013, *CSDA* 61:50–66) cuando el pico es ruidoso o multimodal; (iii) **mFPCA conjunta de amplitud y fase** (Happ, Scheipl, Gabriel & Greven 2019, *Stat* 8:e220), que descompone $X(t) = \tilde{X}(\gamma(t))$ con

γ función de warping. **Reportar siempre dos análisis paralelos** (con y sin alineación) e interpretar FPC2 como *phase-like* sólo si el análisis no-alineado lo sugiere y el alineado lo elimina.

9.2 Transformaciones previas y la interpretación del kernel

Las hormonas peptídicas (GLP-1, GIP, grelina, PYY, insulina) tienen distribuciones aproximadamente lognormales por cinética de pulso multiplicativa y *clearance* de orden cero, y sus ensayos (RIA/ELISA/MSD) presentan CV proporcional a la concentración. **El log-transform es la elección estándar y bioestadísticamente defendible**, con tres consecuencias críticas para la interpretación del kernel:

1. La media estimada $\hat{\mu}_{\log}(t)$ corresponde a la **mediana geométrica** poblacional, robusta a outliers metabólicos (resistencia/diabetes).
2. La covarianza $C_{\log}(s,t)$ es una **covarianza de log-cocientes**: si X es lognormal, $C_{\log}(s,t) \approx \log\big(1+\rho(s,t)\sigma_s\sigma_t/(\mu_s\mu_t)\big)$, interpretable como correlación de respuestas porcentuales en lugar de absolutas.
3. Las eigenfunciones $\hat{\phi}_k(t)$ son **modos multiplicativos**: $X_i(t) \approx \mu_{\text{geom}}(t) \cdot \exp\{\sum_k \hat{\xi}_{ik}\hat{\phi}_k(t)\}$, donde $e^{\hat{\phi}_k(t)}$ es un patrón de *fold-change* sobre la trayectoria mediana.

Para glucosa, donde la lognormalidad es marginal en *fasting*, conviene Box-Cox con λ óptimo (Cole 1988, *JRSS-A* 151:385–418; Miller et al. 2013) y reportar análisis de sensibilidad sin transformación.

9.3 La decisión central: PACE vs cross-sectional vs FACEs para $n=30$–50, $m=9$, MCAR

Recomendación: usar **FACEs** (`face::face.sparse`) como estimador univariado de $\hat{C}^{(jj)}$ y la **construcción multivariada de Happ–Greven** vía `MFPCA::MFPCA` con `type='given'` . PACE (`fdapace::FPCA`) debe reportarse en análisis comparativo por convención del campo, no como método principal. La justificación, en orden:

1. **PACE fue diseñado para diseños "scattered"** (CD4 en VIH, crecimiento infantil), donde los T_{ij} son genuinamente aleatorios. Las propiedades asintóticas óptimas de Hall, Müller & Wang (2006) suponen densidad de pares estocásticamente uniforme, condición que la grilla común balanceada viola: los pares se concentran en cruceros densos sobre la diagonal y son escasos off-diagonal a escala continua, deteriorando la elección de bandwidth bidimensional.
2. **La covarianza muestral cross-sectional con casewise complete pairs es válida pero ruidosa** ($n=30$ implica SE puntual $\sim \sigma^2/\sqrt{30}$ por celda en una matriz 9×9 de 36 covarianzas únicas). Sin *smoothing* los eigenvalores de orden alto son artefactos de varianza muestral, y la PSD no está garantizada con missingness.

3. **FACEs combina lo óptimo**: parte de la covarianza empírica robusta + *smoother* bivariado tensor-producto P-spline que **preserva PSD por la factorización de la base** + LOSO-CV que respeta la unidad sujeto, no la observación + estimación conjunta de σ_ε^2. Las simulaciones publicadas muestran MISE menor y velocidad $\sim \$30 \times respectPCEpr\$m \leq 10$.
4. **Para mFPCA**, Happ–Greven es preferible a la estimación directa por pares de $\hat{C}^{(jk)}$ porque garantiza PSD del operador conjunto por construcción (sección 7.3) y aprovecha el truncamiento univariado para reducción dimensional. `mfaces` (Li, Xiao & Luo 2020) es alternativa razonable de sensibilidad.

9.4 Heteroscedasticidad, censura, outliers y tamaño muestral

Cuatro patologías frecuentes deben reportarse explícitamente: la heteroscedasticidad temporal $\sigma^2(t)$ típicamente desaparece en escala log; los outliers metabólicos (resistencia/diabetes) requieren bien FPCA robusto (Bali et al. 2011) bien análisis estratificado con/sin outliers; la censura por límite de detección (LLOD/ULOQ) admite imputación $\mathrm{LOD}/\sqrt{2}$ si $<10\%$, *multiple imputation* Tobit-lognormal si 10–30%, y análisis Tobit-paciente si $>30\%$ (Helsel 2005); y el tamaño muestral pequeño hace que los SE asintóticos de Hall–Müller–Wang sean optimistas, **siendo el bootstrap por sujetos** $B \geq 1000$ **obligatorio** y la potencia limitada para FPC≥ 3.

9.5 Validación del kernel estimado

El protocolo mínimo de validación que debe figurar en Material Suplementario incluye: (i) heatmap lado a lado de $\hat{C}(t_j, t_l)$ suavizado vs S_{jl}^{emp} empírico crudo en la grilla 9×9, con norma Frobenius de la diferencia; (ii) inspección de residuos $r_{i,jl} = G_{i,jl} - \hat{C}(T_{ij}, T_{il})$ buscando estructura espacial no aleatoria; (iii) verificación de eigenvalores no-negativos en `smoothedCov` y reporte de la varianza negativa eliminada en `fittedCov` ; (iv) bootstrap por sujetos $B = 1000$ para CIs de λ_k, $\phi_k(t)$ y FVE, con percentile o BCa; (v) leave-one-curve-out CV con IMSE de predicción reportado por hormona; (vi) sensibilidad a bandwidth ($h_C \times \{0.5, 1, 2\}$). Justificación bibliográfica del bootstrap: Zhang & Chen (2007, *Ann. Stat.* 35(3):1052–1079), Cuevas, Febrero & Fraiman (2006, *CSDA* 51:1063–1074); el bootstrap por sujetos es el natural para preservar la dependencia within-sujeto, mientras que el bootstrap de residuos rompe la estructura y **no debe usarse en FDA sparse**.

9.6 Antecedentes aplicados en endocrinología metabólica

La aplicación de FPCA a curvas hormonales metabólicas tiene una literatura focalizada pero consolidada. Frøslie, Røislien, Qvigstad et al. (2013, *BMC Med. Res. Methodol.* 13:6) demostraron en $n = 974$ embarazadas con OGTT de 5 puntos que FPC1 (nivel general) correlaciona $r = 0.999$ con AUC pero FPC2 (tiempo al pico) discrimina diabetes gestacional **sin ser captado por AUC**, justificando empíricamente la superioridad de FPCA sobre

métricas escalares. Sauder et al. (2024, MDPI *Endocrines* 5(1):8) replicaron en niños el patrón FPC1–FPC3 con AUC$=0.80$ para predicción de disglicemia, superior a HbA1c (0.72), glucemia *fasting* (0.50) y clasificación bi/monofásica (0.69). Gecili et al. (2021, *J. Clin. Transl. Sci.*) y Sergazinov et al. (2024, arXiv:2405.14690) extienden el marco a CGM continuo en T1D y AEGIS. Este corpus apoya el reporte estandarizado de las **tres componentes principales con interpretación biológica**: amplitud global, *timing* del pico y oscilación residual.

---

10. Conclusión: una metodología defendible y cuatro decisiones críticas

El estado del arte permite concluir con cuatro recomendaciones técnicas defendibles ante revisores de Biometrics o JCEM. Primero, en grillas balanceadas con $n=30$–50 y missingness MCAR, **FACEs domina a PACE** por su tratamiento explícito de la unidad muestral sujeto, su LOSO-CV computacionalmente eficiente y su garantía de PSD por construcción del *smoother* simétrico tensor-producto; PACE debe reportarse como comparador histórico, no como método principal. Segundo, para análisis multivariado de varias hormonas con escalas heterogéneas, **el algoritmo de Happ–Greven con uFPCA por componente y eigendescomposición de la matriz de scores es preferible** a la estimación directa por pares de cross-covarianzas, porque garantiza PSD del operador $\mathbb{H}\to\mathbb{H}$ automáticamente y evita la inestabilidad de elegir $p(p+1)/2$ bandwidths separados. Tercero, **el log-transform es operacionalmente obligatorio** para hormonas peptídicas, transforma $C(s,t)$ en una covarianza relativa interpretable como modos multiplicativos de fold-change y robustece la inferencia frente a outliers metabólicos; debe acompañarse de retro-transformación de eigenfunciones para presentación clínica. Cuarto, **la variabilidad de fase del vaciado gástrico debe inspeccionarse y, si es relevante, separarse explícitamente** mediante registration o el marco amplitud-fase de Happ et al. (2019); sin esto, FPC2 puede ser un artefacto de fase no removida, no una señal biológica genuina.

Las tasas asintóticas verificadas de Yao–Müller–Wang (2005), Hall–Müller–Wang (2006) y Li–Hsing (2010) son condicionales a $n\to\infty$; con $n=30$–50 los errores estándar asintóticos son optimistas, los componentes de orden alto ($k\geq 3$) tienen *eigenvalue gaps* pequeños y las bandas de confianza requieren **bootstrap por sujetos** $B\geq 1000$ como inferencia primaria. La advertencia metodológica reciente de Golovkine et al. (2025) —que la PVE univariada al $\alpha\%$ no garantiza la PVE multivariada al $\alpha\%$— obliga a sobre-parametrizar M_j deliberadamente y seleccionar M conjunto por criterio multivariado a posteriori. La consecuencia general es que la estimación del kernel de covarianza en datos hormonales periprandiales no es un paso instrumental al servicio de FPCA, sino **el corazón estadístico del análisis**: los errores de $\hat{C}$ se propagan, multiplicados, a toda inferencia descendente

sobre fenotipos, scores y bandas de confianza, y por ello la elección de método, la diagnosticación rigurosa y la validación honesta tienen que ocupar el lugar central del manuscrito de Métodos.

Referencias

Aston, J. A. D., Pigoli, D., & Tavakoli, S. (2017). Tests for separability in nonparametric covariance operators of random surfaces. *The Annals of Statistics*, *45*(4), 1431–1461.

Bali, J. L., Boente, G., Tyler, D. E., & Wang, J.-L. (2011). Robust functional principal components: A projection-pursuit approach. *The Annals of Statistics*, *39*(6), 2852–2882.

Berrendero, J. R., Justel, A., & Svarc, M. (2011). Principal components for multivariate functional data. *Computational Statistics & Data Analysis*, *55*(9), 2619–2634.

Cai, T. T., & Yuan, M. (2010). *Nonparametric covariance function estimation for functional and longitudinal data* [Technical report]. University of Pennsylvania & Georgia Institute of Technology.

Cai, T. T., & Yuan, M. (2011). Optimal estimation of the mean function based on discretely sampled functional data: Phase transition. *The Annals of Statistics*, *39*(5), 2330–2355.

Chiou, J.-M., Chen, Y.-T., & Yang, Y.-F. (2014). Multivariate functional principal component analysis: A normalization approach. *Statistica Sinica*, *24*(4), 1571–1596.

Chiou, J.-M., & Müller, H.-G. (2016). A pairwise interaction model for multivariate functional and longitudinal data. *Biometrika*, *103*(2), 377–396.

Cole, T. J. (1988). Fitting smoothed centile curves to reference data. *Journal of the Royal Statistical Society, Series A*, *151*(3), 385–418.

Cuevas, A., Febrero, M., & Fraiman, R. (2006). On the use of the bootstrap for estimating functions with functional data. *Computational Statistics & Data Analysis*, *51*(2), 1063–1074.

Descary, M.-H., & Panaretos, V. M. (2019). Functional data analysis by matrix completion. *The Annals of Statistics*, *47*(1), 1–38.

Di, C.-Z., Crainiceanu, C. M., Caffo, B. S., & Punjabi, N. M. (2009). Multilevel functional principal component analysis. *The Annals of Applied Statistics*, *3*(1), 458–488.

Eilers, P. H. C., & Marx, B. D. (1996). Flexible smoothing with B-splines and penalties. *Statistical Science*, *11*(2), 89–121.

Frøslie, K. F., Røislien, J., Qvigstad, E., Henriksen, T., Godang, K., Bollerslev, J., Voldner, N., Henriksen, T., & Veierød, M. B. (2013). Shape information from glucose curves: Functional data analysis compared with traditional summary measures. *BMC Medical Research Methodology*, *13*, 6.

Gecili, E., Huang, R., Khoury, J. C., King, E., Altaye, M., Bowers, K., & Szczesniak, R. D. (2021). Functional data analysis and prediction tools for continuous glucose-monitoring studies. *Journal of Clinical and Translational Science*, *5*(1), e51.

Goldsmith, J., Bobb, J., Crainiceanu, C. M., Caffo, B., & Reich, D. (2011). Penalized functional regression. *Journal of Computational and Graphical Statistics*, *20*(4), 830–851.

Goldsmith, J., Crainiceanu, C. M., Caffo, B., & Reich, D. (2012). Longitudinal penalized functional regression for cognitive outcomes on neuronal tract measurements. *Journal of the Royal Statistical Society, Series C*, *61*(3), 453–469.

Golovkine, S., Gunning, E., Simpkin, A. J., & Bargary, N. (2025). On the use of the cumulative percentage of variance to select the number of components in MFPCA. *Communications in Statistics — Simulation and Computation*. https://doi.org/10.1080/03610918.2025.2459862

Hall, P., Kay, J. W., & Titterington, D. M. (1990). Asymptotically optimal difference-based estimation of variance in nonparametric regression. *Biometrika*, *77*(3), 521–528.

Hall, P., Müller, H.-G., & Wang, J.-L. (2006). Properties of principal component methods for functional and longitudinal data analysis. *The Annals of Statistics*, *34*(3), 1493–1517.

Hall, P., Müller, H.-G., & Yao, F. (2008). Modelling sparse generalized longitudinal observations with latent Gaussian processes. *Journal of Multivariate Analysis*, *99*(8), 1015–1034.

Happ, C., & Greven, S. (2018). Multivariate functional principal component analysis for data observed on different (dimensional) domains. *Journal of the American Statistical Association*, *113*(522), 649–659.

Happ, C., Scheipl, F., Gabriel, A.-A., & Greven, S. (2019). A general framework for multivariate functional principal component analysis of amplitude and phase variation. *Stat*, *8*(1), e220.

Happ-Kurz, C. (2020). Object-oriented software for functional data. *Journal of Statistical Software*, *93*(5), 1–38.

Helsel, D. R. (2005). *Nondetects and data analysis: Statistics for censored environmental data*. Wiley.

Higham, N. J. (1988). Computing a nearest symmetric positive semidefinite matrix. *Linear Algebra and Its Applications*, *103*, 103–118.

Higham, N. J. (2002). Computing the nearest correlation matrix — a problem from finance. *IMA Journal of Numerical Analysis*, *22*(3), 329–343.

Jacques, J., & Preda, C. (2014). Model-based clustering for multivariate functional data. *Computational Statistics & Data Analysis*, *71*, 92–106.

Li, C., Xiao, L., & Luo, S. (2020). Fast covariance estimation for multivariate sparse functional data. *Stat*, *9*(1), e245.

Li, Y., & Hsing, T. (2010). Uniform convergence rates for nonparametric regression and principal component analysis in functional/longitudinal data. *The Annals of Statistics*, *38*(6), 3321–3351.

Li, Y., Wang, N., & Carroll, R. J. (2013). Selecting the number of principal components in functional data. *Journal of the American Statistical Association*, *108*(504), 1284–1294.

Marron, J. S., Ramsay, J. O., Sangalli, L. M., & Srivastava, A. (2015). Functional data analysis of amplitude and phase variation. *Statistical Science*, *30*(4), 468–484.

Matthews, J. N. S., Altman, D. G., Campbell, M. J., & Royston, P. (1990). Analysis of serial measurements in medical research. *British Medical Journal*, *300*(6719), 230–235.

Miller, R., Plessow, F., Rauh, M., Gröschl, M., & Kirschbaum, C. (2013). Comparison of salivary cortisol as measured by different immunoassays and tandem mass spectrometry. *Psychoneuroendocrinology*, *38*(1), 50–57.

Paciorek, C. J., & Schervish, M. J. (2006). Spatial modelling using a new class of nonstationary covariance functions. *Environmetrics*, *17*(5), 483–506.

Ramsay, J. O., & Silverman, B. W. (2005). *Functional data analysis* (2nd ed.). Springer.

Rice, J. A., & Silverman, B. W. (1991). Estimating the mean and covariance structure nonparametrically when the data are curves. *Journal of the Royal Statistical Society, Series B*, *53*(1), 233–243.

Sauder, K. A., Stamatoiu, A. V., Leshchinskaya, E., Glueck, D. H., Dabelea, D., & Hayes, K. (2024). Utilizing the glucose and insulin response shape of an oral glucose tolerance test to predict dysglycemia in children. *Endocrines*, *5*(1), 8.

Sergazinov, R., Leroux, A., Cui, E., Crainiceanu, C., Aurora, R. N., Punjabi, N. M., & Gaynanova, I. (2024). *Beyond scalar metrics: Functional data analysis of postprandial CGM in AEGIS* [Preprint]. arXiv:2405.14690.

Suarez, A. J., & Ghosal, S. (2017). Bayesian estimation of principal components for functional data. *Bayesian Analysis*, *12*(2), 311–333.

Tucker, J. D., Wu, W., & Srivastava, A. (2013). Generative models for functional data using phase and amplitude separation. *Computational Statistics & Data Analysis*, *61*, 50–66.

Wahba, G. (1990). *Spline models for observational data*. SIAM.

Wang, J.-L., Chiou, J.-M., & Müller, H.-G. (2016). Functional data analysis. *Annual Review of Statistics and Its Application*, *3*, 257–295.

Wilson, A. G., & Ghahramani, Z. (2011). Generalised Wishart processes. *Proceedings of the 27th Conference on Uncertainty in Artificial Intelligence*, 736–744.

Wood, S. N. (2003). Thin plate regression splines. *Journal of the Royal Statistical Society, Series B*, *65*(1), 95–114.

Xiao, L., Li, Y., & Ruppert, D. (2013). Fast bivariate P-splines: The sandwich smoother. *Journal of the Royal Statistical Society, Series B*, *75*(3), 577–599.

Xiao, L., Ruppert, D., Zipunnikov, V., & Crainiceanu, C. (2016). Fast covariance estimation for high-dimensional functional data. *Statistics and Computing*, *26*(1–2), 409–421.

Xiao, L., Li, C., Checkley, W., & Crainiceanu, C. (2018). Fast covariance estimation for sparse functional data. *Statistics and Computing*, *28*(3), 511–522.

Yao, F., Müller, H.-G., & Wang, J.-L. (2005). Functional data analysis for sparse longitudinal data. *Journal of the American Statistical Association*, *100*(470), 577–590.

Zhang, J.-T., & Chen, J. (2007). Statistical inferences for functional data. *The Annals of Statistics*, *35*(3), 1052–1079.