# Geometría del BLUP de PACE y del operador de covarianza en mFPCA

**Documento técnico.** Derivaciones matemáticas rigurosas para Functional Principal Component Analysis (FPCA) y su extensión multivariada (mFPCA), con énfasis en (i) la fundamentación algebraica del Best Linear Unbiased Predictor (BLUP) de Yao, Müller y Wang (2005) y su implementación numérica en `fdapace` 0.6.0, y (ii) la geometría hilbertiana del operador conjunto $\Gamma$ en el marco de Happ y Greven (2018), incluyendo la patología FVE-univariada $\not\Rightarrow$ FVE-multivariada documentada por Golovkine, Gunning, Simpkin y Bargary (2025). **El BLUP de PACE es estructuralmente kriging simple sobre una variable latente escalar** con covarianza derivada de Mercer, y su extensión multivariada admite una representación geométrica como proyección sobre coordenadas Hilbert ortonormales en $\mathcal{H} = \prod_j L^2(\mathcal{T}_j)$. Este resultado tiene consecuencias directas para el fenotipado entero-pancreático con perfiles periprandiales de seis a siete hormonas: la traza ponderada $\sum_j w_j \int C^{(jj)}(t,t)\,dt$ es la varianza funcional total, y la elección $w_j = 1/\widehat{\mathrm{tr}}(\widehat{C}^{(jj)})$ es la única que evita la dominación espuria del primer modo por insulina/glucosa.

---

# Parte I — El BLUP de PACE

## 1. El modelo generativo y los supuestos

Sea $\{X_i(t) : t \in \mathcal{T}\}_{i=1}^n$ una colección i.i.d. de trayectorias de un proceso de segundo orden en $L^2(\mathcal{T})$, con media $\mu(t) = \mathbb{E}[X_i(t)]$ y covarianza continua $C(s,t) = \mathrm{Cov}(X_i(s), X_i(t))$. Por el **teorema de Mercer**,

$$C(s,t) = \sum_{k\geq 1} \lambda_k\, \phi_k(s)\, \phi_k(t), \qquad \lambda_1 \geq \lambda_2 \geq \cdots \geq 0, \quad \sum_k \lambda_k < \infty,$$

con $\{\phi_k\}_{k\geq 1}$ base ortonormal en $L^2(\mathcal{T})$. La **expansión de Karhunen–Loève** (Hsing y Eubank, 2015, cap. 7) da

$$X_i(t) = \mu(t) + \sum_{k\geq 1} \xi_{ik}\, \phi_k(t), \qquad \xi_{ik} = \int_{\mathcal{T}} \big(X_i(t) - \mu(t)\big)\phi_k(t)\,dt,$$

con scores no correlacionados: $\mathbb{E}[\xi_{ik}] = 0$, $\mathbb{E}[\xi_{ik}\xi_{i\ell}] = \lambda_k \delta_{k\ell}$. El modelo de observación con error de medida (Yao, Müller y Wang, 2005, ec. 1) añade ruido idiosincrásico:

$$Y_{ij} = X_i(T_{ij}) + \varepsilon_{ij} = \mu(T_{ij}) + \sum_{k\geq 1} \xi_{ik}\phi_k(T_{ij}) + \varepsilon_{ij}, \quad j = 1, \dots, N_i,$$

con $\varepsilon_{ij} \sim (0, \sigma^2)$ i.i.d., independientes de los scores y de los tiempos $T_{ij}$.

**Caso Gaussiano vs. no Gaussiano.** Si $\{\xi_{ik}\} \cup \{\varepsilon_{ij}\}$ son conjuntamente Gaussianos (supuesto A5 de Yao et al., 2005), entonces $(\boldsymbol{Y}_i, \boldsymbol{\xi}_i)$ es Gaussiano y $\mathbb{E}[\xi_{ik} \mid \boldsymbol{Y}_i]$ coincide con el predictor lineal óptimo. Sin Gaussianidad, $\mathbb{E}[\xi_{ik} \mid \boldsymbol{Y}_i]$ deja de ser lineal en general, pero el predictor lineal de mínimo MSE conserva la forma BLUP — los autores lo afirman literalmente en p. 581: «$\tilde{\xi}_{ik}$ es la mejor predicción lineal de $\xi_{ik}$, dada la información del sujeto $i$, sea o no que se cumpla el supuesto Gaussiano». Las simulaciones del paper documentan robustez frente a mezclas de normales.

## 2. Derivación algebraica del predictor condicional

Fijado el sujeto $i$ y condicionando en $\boldsymbol{T}_i = (T_{i1}, \dots, T_{iN_i})^\top$, definimos

$$\boldsymbol{Y}_i = (Y_{i1}, \dots, Y_{iN_i})^\top, \quad \boldsymbol{\mu}_i = (\mu(T_{i1}), \dots, \mu(T_{iN_i}))^\top,$$

$$\boldsymbol{\phi}_{ik} = (\phi_k(T_{i1}), \dots, \phi_k(T_{iN_i}))^\top \in \mathbb{R}^{N_i}, \quad \boldsymbol{\Phi}_i = [\boldsymbol{\phi}_{i1} \cdots \boldsymbol{\phi}_{iK}], \quad \boldsymbol{\Lambda} = \operatorname{diag}(\lambda_1, \dots, \lambda_K).$$

La estructura conjunta es $\boldsymbol{Y}_i = \boldsymbol{\mu}_i + \boldsymbol{\Phi}_i\boldsymbol{\xi}_i + \boldsymbol{\varepsilon}_i$, con $\boldsymbol{\xi}_i \sim (\boldsymbol{0}, \boldsymbol{\Lambda})$, $\boldsymbol{\varepsilon}_i \sim (\boldsymbol{0}, \sigma^2\boldsymbol{I})$.

**Momentos.** $\mathbb{E}\boldsymbol{Y}_i = \boldsymbol{\mu}_i$ y la covarianza admite la representación de **bajo rango más ruido**:

$$\boxed{\boldsymbol{\Sigma}_{Y_i} = \boldsymbol{\Gamma}_i + \sigma^2\boldsymbol{I}_{N_i} = \boldsymbol{\Phi}_i\boldsymbol{\Lambda}\boldsymbol{\Phi}_i^\top + \sigma^2\boldsymbol{I}_{N_i},} \qquad [\boldsymbol{\Gamma}_i]_{j\ell} = C(T_{ij}, T_{i\ell}).$$

La covarianza cruzada con el score escalar es $\operatorname{Cov}(Y_{ij}, \xi_{ik}) = \lambda_k\phi_k(T_{ij})$, esto es, $\operatorname{Cov}(\boldsymbol{Y}_i, \xi_{ik}) = \lambda_k\boldsymbol{\phi}_{ik}$.

**Lema de la normal multivariada** (Mardia, Kent y Bibby, 1979, Teorema 3.2.4, p. 63). Si $(\boldsymbol{U}, \boldsymbol{V})$ es Gaussiano con bloques $\boldsymbol{\Sigma}_{UU}, \boldsymbol{\Sigma}_{UV}, \boldsymbol{\Sigma}_{VV}$, entonces

$$\mathbb{E}[\boldsymbol{U} \mid \boldsymbol{V}] = \boldsymbol{\mu}_U + \boldsymbol{\Sigma}_{UV}\boldsymbol{\Sigma}_{VV}^{-1}(\boldsymbol{V} - \boldsymbol{\mu}_V), \quad \operatorname{Cov}(\boldsymbol{U} \mid \boldsymbol{V}) = \boldsymbol{\Sigma}_{UU} - \boldsymbol{\Sigma}_{UV}\boldsymbol{\Sigma}_{VV}^{-1}\boldsymbol{\Sigma}_{VU}.$$

Aplicado con $\boldsymbol{U} = \xi_{ik}$, $\boldsymbol{V} = \boldsymbol{Y}_i$:

$$\boxed{\tilde{\xi}_{ik} = \mathbb{E}[\xi_{ik} \mid \boldsymbol{Y}_i] = \lambda_k\,\boldsymbol{\phi}_{ik}^\top\,\boldsymbol{\Sigma}_{Y_i}^{-1}(\boldsymbol{Y}_i - \boldsymbol{\mu}_i).} \qquad (\text{Yao et al., 2005, ec. 4})$$

**BLUP sin Gaussianidad.** Buscando el predictor lineal $\hat{\xi}_{ik} = \boldsymbol{a}^\top\boldsymbol{Y}_i + b$ que minimiza $\mathbb{E}(\xi_{ik} - \hat{\xi}_{ik})^2$, la insesgadez impone $b = -\boldsymbol{a}^\top\boldsymbol{\mu}_i$. Las ecuaciones normales de la proyección $L^2$,

$$\mathbb{E}[(\xi_{ik} - \boldsymbol{a}^\top(\boldsymbol{Y}_i - \boldsymbol{\mu}_i))(\boldsymbol{Y}_i - \boldsymbol{\mu}_i)] = \boldsymbol{0},$$

producen $\boldsymbol{a}^\top = \lambda_k\boldsymbol{\phi}_{ik}^\top\boldsymbol{\Sigma}_{Y_i}^{-1}$, **idéntico** al estimador Gaussiano. Bajo Gaussianidad la

proyección coincide con la condicional; en general es BLUP en el sentido de Goldberger (1962). En la práctica se aplica el plug-in $\hat{\xi}_{ik} = \hat{\lambda}_k \hat{\boldsymbol{\phi}}_{ik}^\top \hat{\boldsymbol{\Sigma}}_{Y_i}^{-1}(\boldsymbol{Y}_i - \hat{\boldsymbol{\mu}}_i)$ (ec. 5 de Yao et al.).

## 3. La varianza de predicción y la conexión con kriging

Aplicando la segunda parte del lema:

$$\boxed{\operatorname{Var}(\xi_{ik} \mid \boldsymbol{Y}_i) = \lambda_k - \lambda_k^2\, \boldsymbol{\phi}_{ik}^\top \boldsymbol{\Sigma}_{Y_i}^{-1} \boldsymbol{\phi}_{ik}.}$$

Para todo el vector de scores se obtiene $\boldsymbol{\Omega}_K = \boldsymbol{\Lambda} - \boldsymbol{\Lambda}\boldsymbol{\Phi}_i^\top \boldsymbol{\Sigma}_{Y_i}^{-1}\boldsymbol{\Phi}_i\boldsymbol{\Lambda}$, expresión usada en las bandas de confianza simultáneas (Yao et al., 2005, Teorema 5).

**Casos extremos.** (a) $N_i \to \infty$ con cobertura densa: $\operatorname{Var}(\xi_{ik} \mid \boldsymbol{Y}_i) \to 0$. (b) $N_i = 0$: $\tilde{\xi}_{ik} = 0$ y $\operatorname{Var}(\xi_{ik} - \tilde{\xi}_{ik}) = \lambda_k$ (varianza marginal). (c) $\sigma^2 \to 0$ con $N_i \geq K$ y $\boldsymbol{\Phi}_i$ de rango pleno: el predictor reproduce los scores exactamente, pero la inversa explota numéricamente y **se requiere regularización**.

**Conexión con kriging simple** (Cressie, 1993, §3.4.5, ecs. 3.2.12–3.2.15). El kriging simple predice $Z(\boldsymbol{s}_0) = \boldsymbol{c}_0^\top \boldsymbol{\Sigma}_Z^{-1}\boldsymbol{Z}$ con varianza $\sigma_K^2 = C(\boldsymbol{s}_0, \boldsymbol{s}_0) - \boldsymbol{c}_0^\top \boldsymbol{\Sigma}_Z^{-1}\boldsymbol{c}_0$. **PACE es estructuralmente kriging simple** sobre la variable latente $\xi_{ik}$ con $\boldsymbol{c}_0 = \lambda_k \boldsymbol{\phi}_{ik}$, $C(\boldsymbol{s}_0, \boldsymbol{s}_0) = \lambda_k$ y «nugget» $\sigma^2$. Yao et al. (2005, p. 580) hacen explícita esta interpretación bayesiana empírica con shrinkage hacia cero.

## 4. La identidad de Woodbury y el coste computacional

La identidad clásica (Henderson y Searle, 1981) aplicada a $\boldsymbol{\Sigma}_{Y_i} = \sigma^2 \boldsymbol{I} + \boldsymbol{\Phi}_i \boldsymbol{\Lambda} \boldsymbol{\Phi}_i^\top$ da

$$(\sigma^2 \boldsymbol{I}_{N_i} + \boldsymbol{\Phi}_i \boldsymbol{\Lambda} \boldsymbol{\Phi}_i^\top)^{-1} = \sigma^{-2}\boldsymbol{I}_{N_i} - \sigma^{-4}\boldsymbol{\Phi}_i\big(\boldsymbol{\Lambda}^{-1} + \sigma^{-2}\boldsymbol{\Phi}_i^\top\boldsymbol{\Phi}_i\big)^{-1}\boldsymbol{\Phi}_i^\top.$$

La inversión directa de $\boldsymbol{\Sigma}_{Y_i} \in \mathbb{R}^{N_i \times N_i}$ es $O(N_i^3)$; vía Woodbury, el cuello de botella es el sistema $K \times K$ y el producto $\boldsymbol{\Phi}_i^\top \boldsymbol{\Phi}_i$, con coste total $O(N_i K^2 + K^3) \approx O(N_i K^2)$ cuando $K \ll N_i$. Los autovalores de $\boldsymbol{\Sigma}_{Y_i}$ están acotados por $\sigma^2$ inferiormente, así que **el número de condición es** $\kappa(\boldsymbol{\Sigma}_{Y_i}) = O(1 + \lambda_1/\sigma^2)$ y diverge cuando $\sigma^2 \to 0$.

## 5. Propiedades asintóticas: tasas de Yao et al. y de Hall et al.

Bajo (A1)–(A6) de Yao et al. (2005) y condiciones de regularidad sobre los anchos de banda:

$$\sup_t |\hat{\mu}(t) - \mu(t)| = O_p((nh_\mu)^{-1/2}), \quad \sup_{s,t} |\hat{C}(s,t) - C(s,t)| = O_p((nh_G^2)^{-1/2}),$$

y los estimadores espectrales heredan la tasa $|\hat{\lambda}_k - \lambda_k| = O_p((nh_G^2)^{-1/2})$, $\|\hat{\phi}_k - \phi_k\|_{L^2} = O_p((nh_G^2)^{-1/2})$. Como consecuencia (Yao et al., 2005, Teorema 3) el plug-in

BLUP $\hat{\xi}_{ik}$ es consistente para el oracle $\tilde{\xi}_{ik}$, pero la convergencia a los **scores verdaderos** $\xi_{ik}$ requiere $K \to \infty$ y diseño suficientemente denso.

**Hall, Müller y Wang (2006), Annals of Statistics 34(3):1493–1517.** Resultado clave: **los autovalores son siempre semiparamétricos**, $|\hat{\lambda}_k - \lambda_k| = O_p(n^{-1/2})$, incluso con $N_i$ acotado y ruido. Las **autofunciones son no paramétricas** en régimen sparse: si la covarianza tiene $r$ derivadas acotadas, la tasa minimax óptima es $\|\hat{\phi}_k - \phi_k\|_{L^2}^2 \sim n^{-2r/(2r+1)}$ (e.g., $n^{-4/5}$ para $r = 2$). En régimen denso ($N_i \to \infty$ suficientemente rápido), las tasas paramétricas $n^{-1/2}$ son alcanzables tanto para autovalores como para autofunciones. Zhang y Wang (2016, Ann. Statist. 44:2281) formalizan la transición de fase. **Sesgo de truncación:** $\mathbb{E}(X_i(t) - X_i^K(t))^2 = \sum_{k>K} \lambda_k \phi_k^2(t) \to 0$ cuando $K \to \infty$.

## 6. Implementación en `fdapace` 0.6.0

La inspección directa del código fuente ( `src/GetIndCEScoresCPP.cpp` ) revela:

```
Eigen::MatrixXd LamPhi = lamVec.asDiagonal() * phiMat.transpose();   // Λ Φᵀ
(K×N_i)
Eigen::LDLT<Eigen::MatrixXd> ldlt_SigmaYi(SigmaYi);                  //
factorización LDLᵀ
xiEst   = LamPhi * ldlt_SigmaYi.solve(yVec - muVec);                 // Λ Φᵀ
Σ_Y⁻¹ (Y−μ)
xiVar   = -LamPhi * ldlt_SigmaYi.solve(LamPhi.transpose());
xiVar.diagonal() += lamVec;                                          // Λ −
Λ Φᵀ Σ_Y⁻¹ Φ Λ
```

La inversión usa **descomposición LDL$^\top$ Eigen**, no la identidad de Woodbury. Una línea histórica `LamPhi * SigmaYi.inverse()` aparece comentada en `GetIndCEScoresCPPnewInd.cpp`, indicando que la única optimización efectiva ha sido sustituir la inversa explícita por un solve estable.

**Construcción de $\mathbf{\Sigma}_{Y_i}$.** Se usa la representación espectral truncada `fittedCov` $= \hat{\mathbf{\Phi}}\hat{\mathbf{\Lambda}}\hat{\mathbf{\Phi}}^\top$ evaluada en `obsGrid` / `truncObsGrid`, no la covarianza suavizada cruda (que puede no ser PSD). El comentario del código en `GetRho.R` lo confirma: `Sigma_Y <- fittedCov + diag(rho, nrow(phi))`.

**El parámetro `methodRho`.** Controla la regularización añadida a la diagonal:

| `methodRho` | Rejilla candidata para $\rho$ | Sustituye $\sigma^2$ por | Efecto sobre $\mathbf{\Sigma}_Y^{-1}$ |
|---|---|---|---|
| `'vanilla'` (default) | — | $\hat{\sigma}^2$ literal; `rho` en output = 0 | Sin regularización extra |

| `methodRho` | Rejilla candidata para $\rho$ | Sustituye $\sigma^2$ por | Efecto sobre $\Sigma_Y^{-1}$ |
|---|---|---|---|
| `'trunc'` | `seq(1,10, length.out=50) * sigma2` | $\rho^*$ óptimo en $[\hat{\sigma}^2, 10\hat{\sigma}^2]$ | Inflación moderada de $\sigma^2$ |
| `'ridge'` | `exp(seq(-13,-1.5,len=50)) * R`, $R = \sqrt{(\int \mu^2 + \sum \lambda)/(b-a)}$ | $\rho^*$ ridge tipo Tikhonov | Penalización proporcional a la energía del proceso |
| `userRho` (escalar) | — | valor fijado | Equivalente a `'trunc'` con valor dado |

La selección de $\rho$ se hace por minimización de `errorRho` (cuadrado de la diferencia entre $\sum \hat{\lambda}_k$ y la varianza integrada de las trayectorias reconstruidas). El valor `'cv-random'` no aparece en el código de v0.6.0 (presumiblemente legado de la versión MATLAB).

**`methodXi='CE'` vs. `'IN'`.** El estimador CE es el BLUP descrito; el estimador IN realiza integración trapezoidal $\hat{\xi}_{ik}^{\mathrm{IN}} = \sum_j (Y_{ij} - \hat{\mu}(T_{ij}))\hat{\phi}_k(T_{ij})\Delta_{ij}$ con shrinkage opcional $\hat{\lambda}_k/(\hat{\lambda}_k + |\mathcal{T}|\hat{\sigma}^2/N_i)$ (Yao 2003). IN es válido únicamente en régimen denso regular; CE es robusto en régimen sparse. Defaults automáticos según `dataType`.

**¿Qué retorna `xiVar`?** Es **una lista de longitud** $n$, cada entrada matriz $K \times K$ que contiene $\hat{\Lambda} - \hat{\Lambda}\hat{\Phi}_i^\top \hat{\Sigma}_{Y_i}^{-1}\hat{\Phi}_i\hat{\Lambda}$. Este objeto es **simultáneamente** la varianza condicional $\mathrm{Var}(\boldsymbol{\xi}_i \mid \boldsymbol{Y}_i)$ (bajo Gaussianidad) y la covarianza del error $\mathrm{Cov}(\boldsymbol{\xi}_i - \hat{\boldsymbol{\xi}}_i)$ del BLUP — coinciden numéricamente bajo plug-in Gaussiano lineal. Para `methodXi='IN'`, `xiVar` se rellena con `NA`.

---

# Parte II — La geometría del operador $\Gamma$ en mFPCA

## 7. El espacio de Hilbert producto

Cada observación es un vector $X = (X^{(1)}, \ldots, X^{(p)})$ con $X^{(j)} \in L^2(\mathcal{T}_j)$, $\mathcal{T}_j \subset \mathbb{R}^{d_j}$ compacto. El espacio ambiente es

$$\mathcal{H} = \prod_{j=1}^{p} L^2(\mathcal{T}_j), \qquad \langle\!\langle f, g \rangle\!\rangle_w = \sum_{j=1}^{p} w_j \int_{\mathcal{T}_j} f^{(j)}(t) g^{(j)}(t)\, dt, \quad w_j > 0.$$

**Proposición 1 (Happ y Greven, 2018).** $\mathcal{H}$ es un espacio de Hilbert separable.

*Demostración:* la bilinealidad y la simetría son inmediatas; la positividad definida sigue de $\langle\!\langle f, f \rangle\!\rangle_w = 0 \iff f^{(j)} = 0$ a.e. para todo $j$. Para la **completitud**, sea $(f_n) \subset \mathcal{H}$ Cauchy: para cada $j$, $\|f_n^{(j)} - f_m^{(j)}\|_2^2 \le w_j^{-1} \|\!| f_n - f_m \|\!|_w^2 \to 0$, luego converge a un $f^{(j)} \in L^2(\mathcal{T}_j)$, y

$f = (f^{(1)}, \dots, f^{(p)})$ es el límite en $\mathcal{H}$. Para la **separabilidad**, la familia numerable $\{w_j^{-1/2} e_k^{(j)} \delta_{j,\cdot}\}_{j,k}$ con $\{e_k^{(j)}\}_k$ ONB de $L^2(\mathcal{T}_j)$ es ONB de $\mathcal{H}$. ■

**Pesos como isometría.** El cambio $\langle\!\langle \cdot, \cdot \rangle\!\rangle \rightsquigarrow \langle\!\langle \cdot, \cdot \rangle\!\rangle_w$ es una isometría diagonal por bloques $\Phi_w : f \mapsto (w_j^{1/2} f^{(j)})_j$ — es decir, **un reescalamiento global por componente**. Sin pesos, el primer modo queda dominado por la componente de mayor varianza absoluta. Happ y Greven (2018, Sec. 5) proponen

$$\boxed{w_j = \Big( \int_{\mathcal{T}_j} \widehat{C}^{(jj)}(t,t)\, dt \Big)^{-1} = \Big[ \widehat{\mathrm{tr}}\big(\widehat{\Gamma}^{(jj)}\big) \Big]^{-1},}$$

de modo que cada componente reescalada satisface $\int \mathrm{Var}(\widetilde{X}^{(j)}(t))\, dt = 1$ — **el análogo funcional de PCA sobre la matriz de correlación** en lugar de sobre la matriz de covarianza.

## 8. El operador de covarianza y su descomposición espectral

El núcleo cruzado $C^{(ij)}(s_i, t_j) = \mathrm{Cov}(X^{(i)}(s_i), X^{(j)}(t_j))$ define el operador

$$(\Gamma f)^{(j)}(t_j) = \sum_{i=1}^{p} \int_{\mathcal{T}_i} C^{(ij)}(s_i, t_j)\, f^{(i)}(s_i)\, ds_i.$$

**Proposición 2 (Happ y Greven, 2018, p. 5).** $\Gamma$ es lineal, autoadjunto, positivo y compacto bajo continuidad uniforme y $\int |C^{(ij)}(s_i, t_j)|^2 ds_i \le K_{ij} < \infty$.

*Esquema de demostración.* La autoadjuntez sigue de $C^{(ij)}(s,t) = C^{(ji)}(t,s)$ por simetría de la covarianza. La positividad se obtiene definiendo $Z_f = \langle\!\langle X - \mu, f \rangle\!\rangle$ y observando que $\langle\!\langle \Gamma f, f \rangle\!\rangle = \mathrm{Var}(Z_f) \ge 0$. La compacidad sigue de mostrar que $\Gamma$ es Hilbert–Schmidt:

$$\|\Gamma\|_{\mathrm{HS}}^2 = \sum_{i,j} \iint |C^{(ij)}(s,t)|^2\, ds\, dt \le \sum_{i,j} K_{ij} |\mathcal{T}_j| < \infty.$$

Por el teorema espectral (Reed y Simon, 1980, Thm. VI.16), existe ONB de autofunciones $\{\Psi_m\}$ con $\Gamma \Psi_m = \nu_m \Psi_m$, $\nu_m \downarrow 0$, $\Psi_m = (\psi_m^{(1)}, \dots, \psi_m^{(p)})$ ortonormales en $\mathcal{H}$. ■

**Proposición 3 (Mercer multivariado, Happ y Greven, 2018).** $C^{(jj)}(s,t) = \sum_m \nu_m \psi_m^{(j)}(s) \psi_m^{(j)}(t)$ con convergencia absoluta y uniforme. La extensión a covarianzas cruzadas es inmediata:

$$\boxed{C^{(jk)}(s,t) = \sum_{m \ge 1} \nu_m\, \psi_m^{(j)}(s)\, \psi_m^{(k)}(t).}$$

Cada modo $m$ aporta un *outer-product cruzado* con el **mismo autovalor** y **las mismas autofunciones acopladas** $(\psi_m^{(j)}, \psi_m^{(k)})$. **Esto es la clave geométrica:** la covarianza cruzada NO factoriza como producto de descomposiciones univariadas. Si uno escribe ingenuamente $C^{(jk)}(s,t) = \sum_a \lambda_a^{(j)} \phi_a^{(j)}(s) \cdot \sum_b \lambda_b^{(k)} \phi_b^{(k)}(t)$, esto correspondería a una

covarianza de rango uno entre componentes, lo cual es trivialmente falso para $p \geq 2$. La estructura correcta es $C^{(jk)}(s,t) = \sum_{a,b} \mathrm{Cov}(\xi_a^{(j)}, \xi_b^{(k)}) \phi_a^{(j)}(s) \phi_b^{(k)}(t)$, y solo la diagonalización del bloque global produce los modos conjuntos.

**Caso $p = 1$.** Con $w_1 = 1$ se recupera la FPCA univariada clásica: $\widehat{\psi}_m = \widehat{\phi}_m$, $\widehat{\rho}_{im} = \hat{\xi}_{im}$ (consistencia notacional).

## 9. La descomposición Karhunen–Loève multivariada

**Proposición 4 (Happ y Greven, 2018).** Bajo los supuestos de Prop. 2,

$$X^{(j)}(t) = \mu^{(j)}(t) + \sum_{m \geq 1} \rho_m \, \psi_m^{(j)}(t), \qquad \rho_m = \sum_{j=1}^{p} w_j \int_{\mathcal{T}_j} (X^{(j)}(t) - \mu^{(j)}(t)) \psi_m^{(j)}(t) \, dt,$$

con $\mathbb{E}\rho_m = 0$ y $\mathrm{Cov}(\rho_m, \rho_n) = \nu_m \delta_{mn}$. La verificación es directa:
$\mathrm{Cov}(\rho_m, \rho_n) = \langle\!\langle \Gamma \Psi_m, \Psi_n \rangle\!\rangle = \nu_m \langle\!\langle \Psi_m, \Psi_n \rangle\!\rangle = \nu_m \delta_{mn}$.

**Por qué los scores capturan covariación entre componentes.** El score $\rho_m$ es **una proyección sobre la dirección de máxima varianza conjunta** del vector funcional, integrando información de todas las componentes simultáneamente. La concatenación ingenua de scores univariados $\{\xi_k^{(j)}\}_{j,k}$ produce coordenadas con $\mathrm{Cov}(\xi_k^{(j)}, \xi_\ell^{(k)}) \neq 0$ para $j \neq k$ — desperdicia la información cruzada. La mFPCA es la **única representación** que descorrelaciona en una sola coordenada por modo y captura simultáneamente cómo varían $X^{(1)}, \ldots, X^{(p)}$ a lo largo del *mismo* modo $m$.

## 10. El teorema de Happ–Greven y el algoritmo de dos etapas

**Proposición 5 (Happ y Greven, 2018, pp. 7–8).** Asumiendo la KL univariada finita $X^{(j)} = \sum_{m=1}^{M_j} \xi_m^{(j)} \phi_m^{(j)}$, los autovalores positivos $\nu_1 \geq \cdots \geq \nu_M > 0$ de $\Gamma$ con $M \leq M_+ := \sum_j M_j$ corresponden a los autovalores positivos de la matriz $\mathbf{Z} \in \mathbb{R}^{M_+ \times M_+}$ con bloques

$$Z_{mn}^{(jk)} = \mathrm{Cov}(\xi_m^{(j)}, \xi_n^{(k)}).$$

Las autofunciones son $\psi_m^{(j)}(t_j) = \sum_{n=1}^{M_j} [\mathbf{c}_m]_n^{(j)} \phi_n^{(j)}(t_j)$ y los scores $\rho_m = \sum_{j,n} [\mathbf{c}_m]_n^{(j)} \xi_n^{(j)} = \boldsymbol{\Xi}_{\cdot} \mathbf{c}_m$.

**Etapa 1.** FPCA univariada por componente: $(\widehat{\phi}_m^{(j)}, \widehat{\lambda}_m^{(j)}, \hat{\xi}_{i,m}^{(j)})$ con $m = 1, \ldots, M_j$, vía PACE para datos sparse o SVD para datos densos.

**Etapa 2.** Construir $\boldsymbol{\Xi} \in \mathbb{R}^{N \times M_+}$ apilando los scores univariados, calcular $\widehat{\mathbf{Z}} = (N-1)^{-1} \boldsymbol{\Xi}^\top \boldsymbol{\Xi}$, y diagonalizar $\widehat{\mathbf{Z}} \widehat{\mathbf{c}}_m = \widehat{\nu}_m \widehat{\mathbf{c}}_m$. Reconstrucción $\widehat{\psi}_m^{(j)} = \sum_n [\widehat{\mathbf{c}}_m]_n^{(j)} \widehat{\phi}_n^{(j)}$.

**Por qué evita la estimación directa de $C^{(jk)}$.** La estimación directa requeriría suavizar $p^2$ superficies de covarianza cruzada en dimensión $d_j + d_k$ y diagonalizar el operador integral resultante en un espacio potencialmente $\sim 10^4$-dimensional. La construcción Happ–

Greven reduce la diagonalización a una matriz de dimensión $M_+ \le \sum_j M_j$, **típicamente menor que 50**.

**Tasas de convergencia (Proposición 7).** Con $r_N^\Gamma = N^{-1/2}$ para datos densos y $r_N^\Gamma = N^{-1/2}h^{-2}$ para sparse PACE,

$$|\nu_m^{[M]} - \widehat{\nu}_m| = O_p(M_{\max}\max(N^{-1/2}, \Delta_M r_N^\Gamma)), \quad \|\psi_m^{[M]} - \widehat{\psi}_m\| = O_p(M_{\max}^{3/2}\max(N^{-1/2}, \Delta_M r_N^\Gamma)).$$

Régimen consistente: $M_j = O(N^\beta)$ con $0 < \beta < (2\alpha+5)^{-1}$ para eigengaps polinomiales $\lambda_m^{(j)} - \lambda_{m+1}^{(j)} \ge C^{-1}m^{-\alpha-1}$.

## 11. Garantía de positividad semidefinida del operador conjunto

**Por qué el plug-in suavizado falla.** Estimadores locales (e.g., polinomial local sobre la *raw covariance* $X_i^{(j)}(s)X_i^{(k)}(t)$) no preservan la condición $\sum_{i,j}\iint f^{(i)}\widehat{C}^{(ij)}f^{(j)} \ge 0$. Como subraya Li, Wang y Carroll (2020), «el método polinomial local es local, no hay garantía de que las estimaciones produzcan un operador de covarianza propiamente definido». El núcleo resultante puede tener autovalores negativos pequeños y exigiría una proyección post-hoc al cono PSD.

**Por qué Happ–Greven garantiza PSD.** $\widehat{\mathbf{Z}} = (N-1)^{-1}\mathbf{\Xi}^\top\mathbf{\Xi}$ es **una matriz de Gram empírica**:

$$\mathbf{v}^\top\widehat{\mathbf{Z}}\mathbf{v} = (N-1)^{-1}\|\mathbf{\Xi}\mathbf{v}\|^2 \ge 0.$$

Sus autovalores $\widehat{\nu}_m \ge 0$ son no negativos por construcción y el operador estimado $\widehat{\Gamma} = \sum_m \widehat{\nu}_m \widehat{\Psi}_m \otimes \widehat{\Psi}_m$ es PSD en $\mathcal{H}$ automáticamente. La estimación **vive intrínsecamente en el cono PSD** $\mathcal{K}_+ \subset \mathcal{S}_2(\mathcal{H})$, sin proyección post-hoc. Para un operador autoadjunto con descomposición $A = \sum \mu_m \Pi_m$, la proyección Frobenius sobre $\mathcal{K}_+$ sería $\Pi_{\mathcal{K}_+}(A) = \sum \mu_m^+ \Pi_m$ — Happ–Greven la evita.

## 12. El BLUP multivariado de los scores $\rho_{im}$

Sea $Y_i^{(j)} = (Y_i^{(j)}(T_{i,k}^{(j)}))_k$ con $\varepsilon_{i,k}^{(j)} \sim \mathcal{N}(0, \sigma_j^2)$. Bajo independencia entre canales del ruido, $\mathbf{\Sigma}_{Y_i}$ es bloque-diagonal y se obtiene

$$\boxed{\widehat{\rho}_{im}^{\text{BLUP}} = \nu_m \sum_{j=1}^{p} w_j\, \boldsymbol{\psi}_m^{(j)}(\mathbf{T}_i^{(j)})^\top \big(\mathbf{\Gamma}_i^{(j)} + \sigma_j^2 \boldsymbol{I}\big)^{-1}\big(\mathbf{Y}_i^{(j)} - \boldsymbol{\mu}^{(j)}(\mathbf{T}_i^{(j)})\big).}$$

La separabilidad por bloques implica un coste $O(\sum_j n_{ij}^3)$ y permite paralelización trivial. Con correlación cruzada de ruido $\mathbf{\Sigma}_\varepsilon^{(jk)} \ne 0$, la fórmula requiere apilar todo: $\mathbf{\Sigma}_{Y_i} = [C^{(jk)}(\mathbf{T}_i^{(j)}, \mathbf{T}_i^{(k)})]_{jk} + \mathbf{\Sigma}_\varepsilon$ y resolver simultáneamente.

**Versión Happ–Greven (paquete `MFPCA` R).** $\widehat{\rho}_{im} = \mathbf{\Xi}_{i,\cdot}\widehat{\mathbf{c}}_m = \sum_{j,n}[\widehat{\mathbf{c}}_m]_n^{(j)}\hat{\xi}_{i,n}^{(j)}$. Esta construcción **hereda automáticamente el shrinkage BLUP de Etapa 1** si los $\hat{\xi}$ se estiman con PACE. La

pérdida por truncación es

$$\|\Gamma - \widetilde{\Gamma}_{M_+}\|_{\mathrm{HS}}^2 \le \sum_{j=1}^{p} w_j^2 \sum_{m>M_j} (\lambda_m^{(j)})^2,$$

y por la desigualdad de Wielandt–Hoffman los $\widehat{\nu}_m$ heredan ese sesgo. **Limitación reconocida** (Li, Wang y Carroll, 2020): en régimen sparse, los scores PACE univariados están encogidos hacia cero, lo que puede infraestimar covariaciones cruzadas en mFPCA; en ese régimen, métodos basados en estimación directa con proyección PSD pueden ser competitivos.

## 13. La patología FVE univariada $\not\Rightarrow$ FVE multivariada (Golovkine et al., 2025)

Definamos $\mathrm{FVE}_{\mathrm{uni}}^{(j)}(M_j) = \sum_{m\le M_j} \lambda_m^{(j)} / \sum_{m\ge 1} \lambda_m^{(j)}$ y $\mathrm{FVE}_{\mathrm{multi}}(M) = \sum_{m\le M} \nu_m / \sum_{m\ge 1} \nu_m$. Happ y Greven (2018, Sec. 3.2) sugieren elegir $M_j$ tal que $\mathrm{FVE}_{\mathrm{uni}}^{(j)} \ge \alpha$ para todo $j$ y luego retener componentes multivariadas hasta el mismo umbral.

**Resultado (Golovkine, Gunning, Simpkin y Bargary, 2025, Communications in Statistics – Simulation and Computation, DOI 10.1080/03610918.2025.2459862; preprint arXiv:2311.04540v3):**

$$\left(\mathrm{FVE}_{\mathrm{uni}}^{(j)}(M_j) \ge \alpha,\ \forall j\right) \not\Longrightarrow \mathrm{FVE}_{\mathrm{multi}}(M_+) \ge \alpha.$$

**Argumento estructural.** La submatriz $\mathbf{Z}$ se construye sobre scores univariados truncados; su rango es $\le M_+$. El sesgo de proyección satisface

$$\sum_{m\ge 1} \nu_m - \mathrm{tr}(\mathbf{Z}) = \sum_{j=1}^{p} w_j \sum_{m>M_j} \lambda_m^{(j)},$$

las colas se *suman* sobre $j$. Aunque cada cola individual sea $(1-\alpha)$ pequeña, su suma puede ser apreciable, y la **estructura de bloques diagonales** tras la truncación univariada destruye covarianzas cruzadas $C^{(ij)}$ que normalmente redistribuyen varianza hacia componentes multivariadas tardías.

**Evidencia empírica.** En simulaciones con $p = 5$, $M = 50$, $\nu_m = \exp(-(m+1)/2)$, $N \in \{25, 50, 100\}$, los valores reales son $\mathrm{NPC}_{99\%} = 10$ pero el criterio univariado retorna $\widehat{\mathrm{NPC}}_{99\%} = 9$ en 497 de 500 réplicas. En el dataset Canadian Weather con $p = 2$, ampliar $M_j$ de 2 a 4 cambia $\widehat{\nu}_3$ de 308 a 438 y $\widehat{\nu}_4$ de 45 a 213, alterando cualitativamente la interpretación. **Recomendación operativa:** tomar $M_j$ generosos (cobertura univariada $\ge 99\%$) y luego aplicar el umbral $\alpha \in \{0.90, 0.99\}$ **directamente sobre la FVE multivariada** $\sum_{m\le M} \widehat{\nu}_m / \sum_m \widehat{\nu}_m$.

**Caveat de rigor.** La afirmación tal como aparece en el paper de Golovkine et al. (2025) es **un resultado empírico de simulación corto (7 págs.)**, no un teorema asintótico formal. El argumento estructural arriba es consecuencia inmediata del esquema de truncado por bloques, pero no se enuncia como teorema separado en el original.

---

# Parte III — Aplicación al fenotipado entero-pancreático periprandial

Considere $p \in \{6, 7\}$ canales hormonales — GLP-1, GIP, ghrelin acilada, ghrelin total, PYY, insulina, glucosa — sobre $\mathcal{T}_j = [0, 180]$ minutos. Las magnitudes son fuertemente heterogéneas: insulina pasa de $\sim 5$ a $> 80$ mU/L (var. multiplicativa $> 16\times$); glucosa varía $\sim 5$ a $\sim 9$ mmol/L; GLP-1 y PYY trabajan en pmol/L con magnitudes muy distintas.

## 14. Construcción operativa

**Espacio ambiente y transformación.** $\mathcal{H} = [L^2[0, 180]]^p$. Es práctica estándar pretransformar $\widetilde{Y}^{(j)}(t) = \log(Y^{(j)}(t) + c_j)$ con $c_j > 0$ pequeño para hormonas con valores cercanos a cero (GLP-1, PYY postprandial), homogeneizando órdenes de magnitud y estabilizando varianzas.

**Traza en escala log.** Tras la transformación,

$$\mathrm{tr}(\Gamma) = \sum_{j=1}^{p} w_j \int_0^{180} \mathrm{Var}(\widetilde{Y}^{(j)}(t))\, dt$$

es la **dispersión multiplicativa total** de los perfiles sobre la ventana 0–180 min. Cada $w_j \int C^{(jj)}(t, t)\, dt$ es la contribución relativa de la hormona $j$ a la variabilidad agregada.

**Sesgo por escala.** Con $w_j \equiv 1$ en escala original, $\nu_1$ está dominado por insulina y glucosa (cuyas varianzas integradas exceden a las de las incretinas y ghrelinas en uno o dos órdenes de magnitud). La autofunción $\Psi_1$ resultaría casi colineal con $(0, \ldots, 0, X^{\text{insulina}}, X^{\text{glucosa}})$, **ocultando la señal entero-pancreática** que es precisamente el objeto de interés. La normalización $w_j = 1/\widehat{\mathrm{tr}}(\widehat{C}^{(jj)})$ resuelve esto: cada feature contribuye exactamente 1 a $\mathrm{tr}(\Gamma)$ y las componentes principales reflejan **patrones de forma adimensionales** en lugar de escalas absolutas.

## 15. Distancias y clasificación PTP/IEP

Por la isometría de Parseval,

$$d^2_{\mathcal{H}}(x_i, x_{i'}) = \sum_{m \geq 1} (\rho_{im} - \rho_{i'm})^2,$$

aproximado por $\widehat{d}^2(i,i') = \sum_{m \le M^*} (\widehat{\rho}_{im} - \widehat{\rho}_{i'm})^2$. La **distancia de Mahalanobis funcional**

$$\widehat{\Delta}^2(i,i') = \sum_{m \le M^*} \frac{(\widehat{\rho}_{im} - \widehat{\rho}_{i'm})^2}{\widehat{\nu}_m}$$

satisface $\widehat{\Delta}^2 \overset{d}{\approx} \chi^2_{M^*}$ bajo Gaussianidad de scores (Mardia, Kent y Bibby, 1979, §3.5).

**Implicación geométrica.** La clasificación PTP (postprandial-tolerance phenotype) vs. IEP (impaired enteropancreatic phenotype) basada en $(\widehat{\rho}_{i1}, \ldots, \widehat{\rho}_{iM^*})$ es **geométricamente equivalente** a clasificar en $L^2[0,180]^p$ pero con dimensión drásticamente reducida. Las reglas LDA/QDA/Bayes plug-in en $\mathbb{R}^{M^*}$ heredan la métrica de Mahalanobis. El número de componentes $M^*$ debe seleccionarse siguiendo Golovkine et al. (2025): $M_j$ generosos primero (cobertura $\geq 99\%$), después $\alpha \in \{0.90, 0.99\}$ sobre la FVE multivariada.

## 16. Pseudocódigo R para reproducción manual del BLUP en `fdapace`

```
manual_blup <- function(res, Ly, Lt) {
  K        <- length(res$lambda)
  obsGrid  <- res$obsGrid
  workGrid <- res$workGrid
  # 1) Llevar mu y phi a obsGrid (replicar ConvertSupport)
  muObs  <- approx(workGrid, res$mu,  xout = obsGrid, rule = 2)$y
  phiObs <- apply(res$phi, 2, function(v)
                  approx(workGrid, v, xout = obsGrid, rule = 2)$y)
  CovObs <- res$fittedCov                        # PSD por construcción
  s2     <- if (res$optns$methodRho == 'vanilla') res$sigma2 else res$rho

  xiEst_manual <- matrix(NA_real_, nrow = length(Ly), ncol = K)
  xiVar_manual <- vector("list", length(Ly))
  for (i in seq_along(Ly)) {
    t_i  <- Lt[[i]];  y_i <- Ly[[i]]
    idx  <- match(t_i, obsGrid)
    mu_i  <- muObs[idx]
    Phi_i <- phiObs[idx, , drop = FALSE]        # n_i × K
    Cov_i <- CovObs[idx, idx, drop = FALSE]
    Sig_i <- Cov_i + diag(s2, length(t_i))      # Φ Λ Φᵀ + σ²I
    ch     <- chol(Sig_i + diag(1e-12, length(t_i)))
    sol_y  <- backsolve(ch, forwardsolve(t(ch), y_i - mu_i))
    sol_P  <- backsolve(ch, forwardsolve(t(ch), Phi_i))
    LamPhi <- diag(res$lambda, K, K) %*% t(Phi_i)
    xiEst_manual[i, ] <- LamPhi %*% sol_y                       # Λ Φᵀ Σ_Y⁻¹
(y−μ)
    xiVar_manual[[i]] <- diag(res$lambda, K, K) −
                         LamPhi %*% sol_P %*% diag(res$lambda, K, K)
  }
```

```
  list(xiEst = xiEst_manual, xiVar = xiVar_manual)
}
# Verificación: all.equal(manual_blup(res, Ly, Lt)$xiEst, res$xiEst,
tolerance = 1e-6)
```

Advertencias prácticas: respetar el binning si `useBinnedData='AUTO'`; replicar `ConvertSupport` bilineal cuando la rejilla difiera; usar `chol` o `LDL` con estabilizador.

---

## Conclusiones y síntesis

El BLUP de PACE y el operador conjunto de mFPCA son **dos manifestaciones del mismo objeto geométrico**: la proyección sobre coordenadas Hilbert de un proceso vectorial. La fórmula $\tilde{\xi}_{ik} = \lambda_k \boldsymbol{\phi}_{ik}^\top \boldsymbol{\Sigma}_{Y_i}^{-1}(\boldsymbol{Y}_i - \boldsymbol{\mu}_i)$ es estructuralmente kriging simple sobre una variable latente escalar y conserva la propiedad BLUP fuera del régimen Gaussiano por minimización de MSE en la clase lineal. La implementación en `fdapace` 0.6.0 resuelve el sistema con LDL$^\top$ (no Woodbury), retorna `xiVar` como covarianza del error de predicción $K \times K$ por sujeto — equivalente bajo Gaussianidad a la varianza condicional — y regulariza vía `methodRho` cuando $\sigma^2$ se aproxima a cero.

Tres consecuencias merecen énfasis. **Primero**, la construcción Happ–Greven en dos etapas no es solo computacionalmente conveniente: es el único método plug-in que vive intrínsecamente en el cono PSD del espacio de operadores Hilbert–Schmidt, eliminando la necesidad de proyección post-hoc que afecta a los estimadores kernel-suavizados directos. **Segundo**, el resultado de Golovkine et al. (2025) refuta la heurística natural de aplicar el mismo umbral $\alpha$ a la FVE univariada y multivariada: las colas de varianza se suman sobre componentes y la truncación univariada destruye covarianzas cruzadas que en general redistribuyen varianza hacia componentes multivariadas tardías. La práctica correcta es generosa en $M_j$ y selectiva en $M$ con criterio aplicado directamente sobre la FVE multivariada. **Tercero**, para el fenotipado entero-pancreático periprandial, la elección de pesos $w_j = 1/\widehat{\mathrm{tr}}(\widehat{C}^{(jj)})$ junto con transformación logarítmica es la única estrategia que evita la dominación espuria del primer modo por insulina/glucosa y permite que las componentes principales reflejen patrones de forma hormonal adimensionales relevantes para la clasificación PTP/IEP. La aplicación específica de mFPCA con BLUP a estos seis o siete canales hormonales no aparece publicada al 8 de mayo de 2026 en la literatura indexada — la metodología propuesta es una extensión coherente y novedosa del marco Happ–Greven y Yao–Müller–Wang para datos longitudinales sparse multivariados.

---

## Referencias verificadas (APA con DOI)

Chiou, J.-M., Chen, Y.-T., y Yang, Y.-F. (2014). Multivariate functional principal component analysis: A normalization approach. *Statistica Sinica*, 24, 1571–1596.

Cressie, N. (1993). *Statistics for Spatial Data* (rev. ed.). Wiley.

Golovkine, S., Gunning, E., Simpkin, A. J., y Bargary, N. (2025). On the estimation of the number of components in multivariate functional principal component analysis. *Communications in Statistics – Simulation and Computation*. https://doi.org/10.1080/03610918.2025.2459862

Hall, P., y Horowitz, J. L. (2007). Methodology and convergence rates for functional linear regression. *The Annals of Statistics*, 35, 70–91.

Hall, P., Müller, H.-G., y Wang, J.-L. (2006). Properties of principal component methods for functional and longitudinal data analysis. *The Annals of Statistics*, 34(3), 1493–1517. https://doi.org/10.1214/009053606000000272

Happ, C., y Greven, S. (2018). Multivariate functional principal component analysis for data observed on different (dimensional) domains. *Journal of the American Statistical Association*, 113(522), 649–659. https://doi.org/10.1080/01621459.2016.1273115

Happ-Kurz, C. (2020). Object-oriented software for functional data. *Journal of Statistical Software*, 93(5), 1–38. https://doi.org/10.18637/jss.v093.i05

Henderson, H. V., y Searle, S. R. (1981). On deriving the inverse of a sum of matrices. *SIAM Review*, 23, 53–60.

Hsing, T., y Eubank, R. (2015). *Theoretical Foundations of Functional Data Analysis, with an Introduction to Linear Operators*. Wiley.

Li, Y., Wang, N., y Carroll, R. J. (2020). Comments on multivariate functional principal component analysis. *Stat*, 9, e245.

Mardia, K. V., Kent, J. T., y Bibby, J. M. (1979). *Multivariate Analysis*. Academic Press.

Ramsay, J. O., y Silverman, B. W. (2005). *Functional Data Analysis* (2nd ed.). Springer.

Reed, M., y Simon, B. (1980). *Methods of Modern Mathematical Physics I: Functional Analysis*. Academic Press.

Werner, D. (2011). *Funktionalanalysis* (7th ed.). Springer.

Yao, F., Müller, H.-G., y Wang, J.-L. (2005). Functional data analysis for sparse longitudinal data. *Journal of the American Statistical Association*, 100(470), 577–590. https://doi.org/10.1198/016214504000001745

Zhang, X., y Wang, J.-L. (2016). From sparse to dense functional data and beyond. *The Annals of Statistics*, 44(5), 2281–2321.

**Software.** Paquete `fdapace` 0.6.0 (CRAN), https://cran.r-project.org/package=fdapace; código fuente https://github.com/functionaldata/tPACE. Paquete `MFPCA` (CRAN), https://github.com/ClaraHapp/MFPCA. Código de Golovkine et al. (2025): https://github.com/FAST-ULxNUIG/variance_mfpca.